



Evaluación y Simplificación de textos para enseñanza de Inglés 2022

Informe de Proyecto de Grado presentado al Tribunal Evaluador
como requisito de graduación de la carrera Ingeniería en Computación

ESTUDIANTES:

RUIZ COLOMBATO, FACUNDO JOAQUIN

4.747.599-5

NOEL MUSSO, ANDRÉS ALEXANDRE

4.608.273-7

SUPERVISORES:

AIALA ROSÁ

LUIS CHIRUZZO

Resumen

La comunicación en la lengua inglesa es imprescindible en el mundo de hoy, la globalización ha hecho que así lo sea. El inglés es la lengua internacional, usada para escribir los estudios más recientes, viajar por el mundo y expandir nuestros emprendimientos permitiendo la comunicación con personas de otro país en este lenguaje universal.

El proyecto presentado en este informe busca continuar con una línea de trabajo de investigación e implementación de herramientas de apoyo a la enseñanza de inglés para proveer a las escuelas. En esta oportunidad, se presenta una investigación acompañada con el desarrollo de herramientas con técnicas de Procesamiento de Lenguaje Natural para poder evaluar y simplificar textos en inglés con el objetivo de saber si son acordes al nivel necesario para que los estudiantes puedan aprender. Los textos fueron evaluados por la herramienta implementada para determinar su grado de complejidad, y simplificados para mejorar el aprendizaje en esta etapa temprana.

Se realizaron actividades de vinculación con estudiantes de la Facultad de Información y Comunicación, que en conjunto con una lingüista, trabajaban sobre la simplificación de textos. En estas reuniones se generaron ideas y aspectos claves a considerar cuando se simplifica.

Distintas métricas de evaluación fueron puestas a prueba contra grandes cantidades de textos de distintas fuentes, clasificados por profesionales según su complejidad. Luego de elegir técnicas fiables para evaluar textos, estos fueron simplificados y se volvieron a evaluar para estudiar la efectividad de los métodos de simplificación.

Se experimentó con técnicas de simplificación de dos tipos: léxicas y sintácticas.

Para realizar simplificación léxica, se identificaron palabras complejas con un clasificador SVM basado en vocabulario y se sustituyeron por palabras más simples con BERT-LS.

BERT-LS toma en cuenta tanto el contexto del enunciado como la palabra compleja a la hora de generar candidatos para sustituir la palabra.

Para realizar simplificación sintáctica, se aplicaron reglas para reducir la complejidad de los enunciados, que fueron previamente analizados sintácticamente.

Finalmente, se considera que el trabajo realizado cumplió con los objetivos planteados al inicio del proyecto. Se logró implementar una herramienta para evaluar y simplificar textos que podrá facilitar el trabajo de la enseñanza de inglés en niños.

Palabras claves: inglés, procesamiento de lenguaje natural, ANEP, support vector machine, word embeddings, evaluación de textos, simplificación de textos, BERT.

Índice

1. Introducción	4
1.1. Motivación	5
1.2. Objetivos	5
1.2.1. Objetivos Generales	5
1.2.2. Objetivos Específicos	6
2. Marco teórico	7
2.1. Procesamiento de lenguaje natural	7
2.1.1. Pre-procesamiento de textos en PLN	9
2.1.2. Part-of-Speech Tags	10
2.1.3. Resolución de Correferencias	10
2.1.4. Análisis Sintáctico	11
2.2. Aprendizaje automático	12
2.2.1. Aprendizaje supervisado:	12
2.2.2. Aprendizaje no supervisado:	14
2.3. Modelos de lenguaje	15
2.3.1. Word embedding	15
2.3.2. BERT	15
2.4. Evaluación de complejidad de textos	16
2.4.1. Métricas de evaluación de texto	16
2.5. Trabajos relacionados	20
2.5.1. Evaluación de complejidad	20
2.5.2. Simplificación de textos	23
2.5.2.1. Simplificación léxica	23
2.5.2.2. Simplificación sintáctica	28
3. Evaluación de Textos	32
3.1. Recopilación de corpus	32
3.2. Textos Ejemplo Desarrollados	36
3.3. Clasificar palabras según su grado de complejidad	39
3.3.1. Recursos	39
3.3.2. Clasificador	39
3.3.3. Experimentos	40
3.3.4. Resultados	42
4. Simplificación de Textos	43
4.1. Sustitución léxica en palabras complejas con BERT-LS	43
4.1.1. Experimentación	43
4.1.2. Resultados	44

4.2. Resolución de correferencias	48
4.3. Reglas Sintácticas	49
5. Experimentación	54
6. Conclusiones y Trabajo Futuro	60
6.1. Conclusiones	60
6.2. Trabajo a futuro	61
Bibliografía	63
A. CEFR Levels	67
B. Ejemplos de sustitución manual	68
C. Reglas de Transformación del artículo Syntactic simplification and Text Cohesion	75
D. POS Tags del Penn Treebank Project	78
E. Tablas de resultado métricas	78

1. Introducción

Actualmente, la enseñanza de inglés en el Uruguay se desarrolla en gran parte del país gracias a diferentes proyectos y herramientas que así lo fomentan.

Uno de estos proyectos, es el de “Uruguay Plurilingüe 2030” de ANEP, el cual establece como objetivo que "todos los alumnos que egresen de bachillerato de la enseñanza media pública deberán hacerlo con un nivel intermedio/avanzado de inglés"[3].

Llevar a cabo esta tarea resulta difícil en las escuelas rurales ya que no cuentan con suficientes profesores de inglés para trabajar, debido en parte a que se encuentran en zonas de difícil acceso. Además se encuentran en zonas de mala conectividad, lo que impide la enseñanza por videoconferencia en las escuelas. Por otra parte, la mayoría de las escuelas rurales del Uruguay son multigrado, lo que plantea un desafío más grande a la hora de generar material de estudio [3].

Esto tiene como consecuencia que los alumnos tengan más dificultades para poder llegar a los niveles ideales de inglés al terminar la educación primaria.

En los últimos años, el grupo Procesamiento de Lenguaje Natural (PLN) de la Facultad de Ingeniería ha trabajado en conjunto con el Programa de Políticas Lingüísticas de ANEP con el objetivo de proveer herramientas que sirvan de apoyo para la enseñanza de inglés a nivel de primaria.

Al comienzo del proyecto se realizó una reunión con estudiantes de la Facultad de Información y Comunicación (UdelaR) que en conjunto con una lingüista especializada en inglés se estaban ocupando de simplificar textos de forma manual. Se trabajó en conjunto con el objetivo de identificar heurísticas y propiedades del texto que ayudarían a leer el texto de forma más fácil.

En este proceso, se identificó que:

- Existen palabras complejas que se podrían sustituir por un sinónimo más legible en concordancia con el nivel del alumno.
- Es posible implementar diversas reglas sintácticas que descomponen el texto para que sea más legible.
- Puede ser útil resolver correferencias y eliminar información extra.

En el Anexo B se podrán ver algunas de las simplificaciones manuales que se realizaron.

El proyecto presentado en este informe presenta herramientas que podrían permitir a estudiantes y profesores acceder a textos evaluados y simplificados a un nivel de complejidad acorde para su correcto aprendizaje.

Las técnicas elegidas son basadas en los métodos más modernos del área PLN, tales como Word Embeddings y redes neuronales, para intentar obtener los mejores resultados basados en el estado del arte actual.

1.1. Motivación

Fueron varios los motivos que desde el primer momento nos impulsaron a trabajar en este proyecto.

En todo nuestro paso por la facultad, luego de realizar diferentes trabajos e insertarnos en el ambiente laboral, fuimos tomando conciencia de la importancia del inglés en el mundo de hoy para mantenernos a la vanguardia, pudiendo comunicarnos con personas de cualquier parte del mundo de habla inglesa o que utilizan el inglés como lengua franca. Esto permite generar más oportunidades de trabajo y aprender de los últimos avances del mundo, los cuales generalmente están publicados en este idioma. Es por esto que trabajar en un proyecto relacionado con la educación y el inglés, especialmente en su etapa inicial, nos resultó muy motivante, ya que creemos fuertemente que los niños de nuestro país lo necesitan para generar mayores oportunidades el día de mañana.

Como también somos estudiantes de inglés, sabemos que esto puede resultar tedioso si no se encuentra el encanto hacia el nuevo idioma. La elección adecuada de textos es crucial para la enseñanza de idiomas. Si los estudiantes reciben materiales más complejos que su nivel de comprensión, o demasiado simples, podrían llegar a desmotivarse. A su vez, textos que contienen enunciados largos, palabras inusuales y estructura lingüística compleja pueden ser muy difíciles de entender para los niños. Es por esto que pensamos que es crucial contar con las herramientas y recursos necesarios para estimular la motivación de los estudiantes para el aprendizaje.

Por otra parte, fuimos estudiantes de la materia 'Introducción al Procesamiento del Lenguaje Natural' y nos interesó desarrollar la tesis en esta área para profundizar nuestros conocimientos y experimentar en este campo de las ciencias de la computación que tanto avance ha generado en los últimos años.

1.2. Objetivos

1.2.1. Objetivos Generales

Este proyecto, que se realizó en el marco de una colaboración con el Programa de Políticas Lingüísticas de ANEP (PPL-ANEP) y que forma parte del Espacio de Formación Integral (EFI) CINACINA (Capacitación en INglés en el Aula Con Inteligencia Artificial), propone la aplicación de técnicas de Procesamiento de Lenguaje Natural (PLN) para la construcción de herramientas que den soporte a la enseñanza de inglés a alumnos de escuelas rurales en diferentes departamentos del Uruguay.

En esta ocasión, se propone la construcción de herramientas que permitan la evaluación y simplificación de textos a un nivel de complejidad acorde para su correcto aprendizaje. Esto permitirá obtener una base de textos para estudiantes iniciales de inglés.

1.2.2. Objetivos Específicos

Los objetivos específicos del proyecto son:

- Recopilar un corpus de textos clasificados según su complejidad.
- Estudiar y seleccionar métricas para evaluación de complejidad de textos.
- Evaluar las métricas de evaluación para confirmar la correcta elección.
- Estudiar e implementar técnicas de simplificación de textos.
- Evaluar la simplificación utilizando las métricas de evaluación seleccionadas.

2. Marco teórico

En este capítulo se explicarán conceptos necesarios utilizados como base para la realización de este proyecto.

En la última sección de este capítulo, se presentará un relevamiento del estado del arte en cuanto a herramientas y recursos para la evaluación y simplificación de textos.

2.1. Procesamiento de lenguaje natural

El Procesamiento de Lenguaje Natural (PLN) es una subdisciplina de la Inteligencia Artificial que intenta resolver, con computadoras, tareas vinculadas al lenguaje humano, permitiendo la comunicación entre el humano y la computadora a través del lenguaje natural o resolviendo diferentes tareas que implican algún tipo de procesamiento de texto o habla [24].

El gran problema del procesamiento del lenguaje natural es entender las diferentes interpretaciones que un texto puede ofrecer, es decir, resolver la ambigüedad.

Para entender el problema, se presentarán algunas categorías de ambigüedad junto con ejemplos [19]:

- **Homonimia:** Dos palabras con misma forma que tienen distinto significado

Ejemplo: 'I saw a bat.'

- bat = mamífero volador / palo de madera
- saw = pasado de ver / sierra

- **Polisemia:** Una palabra con múltiples significados

Ejemplo: 'He hit the bat with a baseball bat'

- **Sintáctica:** Un enunciado tiene varios árboles de análisis sintáctico (Concepto detallado en capítulo 2.1.4).

Ejemplo: 'Pedro saw Juan with the telescope'

- Pedro saw [Juan] with the telescope
- Pedro saw [Juan with the telescope]

- **Anafórica:** Palabra o frase que refiere a algo previo, pero hay más de una posibilidad. Ejemplo: 'Margaret invited Susan for a visit, and she gave her a good lunch.'

She puede hacer referencia a Margaret o a Susan.

Una de las grandes claves para desambiguar, al igual que lo hacemos los humanos, es tener en cuenta el contexto. Esto permite tener una idea más general, y así entender a qué se hace referencia en cada caso de los antes vistos.

Algunas aplicaciones típicas del Procesamiento de Lenguaje Natural son:

- **Traducción Automática de Textos:** Es posible generar algoritmos capaces de traducir de un idioma a otro sin la intervención humana en el proceso, aplicación que ayuda a la globalización y accesibilidad de la información.
- **Análisis de Sentimientos:** Intenta clasificar tanto texto como habla para inferir los sentimientos detrás del contenido. Es muy utilizado en redes sociales tales como Twitter, para obtener la opinión general de un tópico a elección, como pueden ser desde reseñas de películas hasta la opinión de la sociedad sobre alguna declaración política, etc

En este trabajo estudiamos los siguientes problemas, que se analizarán en detalle más adelante en los siguientes capítulos:

- **Evaluación de complejidad de Textos:**

Se puede desarrollar un sistema que se centre en el análisis de legibilidad del texto para automatizar el proceso de selección de material de lectura adecuado para el caso en cuestión, como por ejemplo, estudiantes de determinado grado.

En la sección 2.5.2 y en el capítulo 3 se podrán ver más detalles sobre aplicaciones de evaluación de complejidad de textos con herramientas de PLN.

- **Simplificación de textos:**

La simplificación de textos consiste en modificar el contenido y estructura del texto para que, sin perder el significado original, sea más comprensible y fácil de leer.

A continuación se presentan un par de ejemplos de enunciados complejos y sus simplificaciones realizadas por humanos [27]:

Enunciado Complejo 1: *Owls are the order Strigiformes, comprising 200 bird of prey species.*

Enunciado Simplificado 1: *An owl is a bird. There are about 200 kinds of owls.*

Enunciado Complejo 2: *Owls hunt mostly small mammals, insects, and other birds though some species specialize in hunting fish.*

Enunciado Simplificado 2: *Owls' prey may be birds, large insects (such as crickets), small reptiles (such as lizards) or small mammals (such as mice, rats, and rabbits).*

Se observan las siguientes transformaciones:

- Palabras complejas (*comprising*) son sustituidas por palabras o expresiones más simples (*There are about*)
- Estructuras sintácticas son modificadas por patrones más simples (el primer enunciado es dividido en dos).
- Información poco importante es eliminada (en el segundo enunciado, "*though some species specialize in hunting fish*" no aparece en su versión simplificada)
- Se le agregan explicaciones o ejemplos a conceptos inusuales ("*insects (such as crickets), small reptiles (such as lizards)*")

Este tipo de transformaciones son algunos de los objetivos de los modelos de simplificación de textos [37].

En el capítulo 4 se podrán ver más detalles sobre aplicaciones de simplificación de complejidad de textos con herramientas de PLN.

2.1.1. Pre-procesamiento de textos en PLN

En PLN, el pre-procesamiento de los textos es la primera etapa para construir un modelo.

Generalmente, se siguen los siguientes pasos:

- Tokenizar los enunciados: Se dividen los enunciados en palabras.
- Transformar palabras a minúscula: Se convierte cada palabra a minúscula.
- Eliminar stop-words: Se conoce como stop words a palabras muy frecuentes en un vocabulario (ejemplo *the* y *a* en el idioma inglés).

Existen listas stop words ya predefinidas.

Muchos sistemas de PLN ignoran estas palabras al momento de procesar textos con la idea de que estos términos aportan poco peso semántico [24].

- Lematización: Es el proceso de convertir cada palabra en su forma base.

2.1.2. Part-of-Speech Tags

POS Tags: Las part-of-speech (categorías gramaticales) son categorías de palabras basadas en la función de la palabra en un enunciado.

Las 8 part-of-speech tradicionales en inglés incluyen:

- Noun (sustantivo)
- Verb (verbo)
- Pronoun (pronombre)
- Preposition (preposición)
- Adverb (adverbio)
- Conjunction (conjunción)
- Participle (participio)
- Article (artículo)

Existen listas que incluyen más categorías (tagsets), como Penn Treebank[28] que lista 45 categorías (ver en Anexo D).

Tagging Part-of-speech tagging es el proceso de asignar una part-of-speech a cada palabra de un texto. Las palabras pueden ser ambiguas y tener más de una part-of-speech posible; el objetivo del proceso es categorizar la palabra correctamente para el contexto.

Por ejemplo - la palabra *book* puede ser categorizada tanto como verbo: “*Book that flight.*” o como sustantivo: “*Hand me that book.*”

Este es un problema muy estudiado en el área de PLN y varios algoritmos han sido desarrollados con resultados muy precisos (accuracy de más de 96% comparado con el Gold Standard, un conjunto de palabras y part-of-speech etiquetadas por humanos, para tagsets como Penn Treebank) [24].

2.1.3. Resolución de Correferencias

Una correferencia ocurre cuando en un texto existen dos o más expresiones que refieren a la misma entidad (persona, organización, lugar).

Por ejemplo, para el texto:

***Patrick Bateman** lives in the American Garden buildings. **He** is 27 years old.*

Patrick Bateman y el pronombre *He* refieren a la misma persona.

El objetivo de la resolución de correferencias consiste en analizar un texto, resolviendo para este tipo de expresiones a qué entidad se están refiriendo. Este es un problema difícil de resolver automáticamente debido a la ambigüedad que puede ocurrir en las expresiones. La resolución de correferencias es importante para varias tareas del PLN como la extracción de información y el resumen automático de textos [24].

Existen varias herramientas que implementan diferentes algoritmos para la solución de este problema. Una de ellas es el módulo de Resolución de Correferencias de AllenNLP[4], el cual utiliza un modelo basado en Word Embeddings y BERT (ver conceptos en capítulos 2.3.1 y 2.3.2 respectivamente) para la resolución.

2.1.4. Análisis Sintáctico

Este análisis tiene como objetivo ver la estructura que forman los enunciados y cómo las palabras se combinan para formar construcciones gramaticales correctas.

Una forma de realizar este análisis es mediante una estructura arborescente desglosando el enunciado en sus categorías sintácticas formadas por cada una de las unidades léxicas que aparecen en el enunciado.

Las categorías o componentes sintácticos que aparecen en el enunciado, denominados sintagmas (los grupos de palabras que constituyen una unidad sintáctica), cumplen una función determinada con respecto a otras palabras del enunciado.

En la Figura 2 se puede ver un ejemplo de análisis sintáctico donde, teniendo en cuenta la gramática, se va desglosando el enunciado en los distintos grupos de constituyentes (grupo preposicional, grupo nominal, grupo verbal, etc) hasta llegar a construir el árbol sintáctico del enunciado.




Figura 2: Árbol Sintáctico para el enunciado "The dog ate the bone"

2.2. Aprendizaje automático

El aprendizaje automático también es una subdisciplina de la Inteligencia Artificial, en la que se usan diferentes técnicas y algoritmos con el objetivo de que los sistemas puedan predecir y tomar decisiones en base a datos, los cuales se conocen como instancias de entrenamiento.

Según si el sistema tiene o no acceso al valor esperado para las instancias de entrenamiento, se está bajo tareas de aprendizaje supervisadas o no supervisadas.

2.2.1. Aprendizaje supervisado:

Una de las tareas fundamentales que se puede resolver mediante aprendizaje supervisado es el problema de clasificación.

Problema de clasificación: Trata de reconocer entidades agrupándolas en un conjunto discreto de clases.

Muchas tareas de PLN pueden verse como problemas de clasificación:

- Clasificar una película como buena o mala
- Clasificar un mail como spam
- Reconocer comentarios positivos, negativos o neutros
- Saber si una palabra en un lenguaje específico se considera compleja: en este trabajo se describirá más de este tema en la sección 3.3

Mediante aprendizaje automático se puede resolver el problema infiriendo algún modelo a partir de los datos de entrenamiento para aplicar a las nuevas instancias. Otra forma, no tan eficiente, es generar reglas precisas para clasificar entidades conociendo la realidad. Combinar ambas técnicas podría mejorar los resultados.

Para poder evaluar el rendimiento del modelo cuando se trata de aprendizaje automático, el método más usual consiste en dividir el corpus en un gran porcentaje de datos de entrenamiento y el resto en datos de evaluación (por ejemplo 80 % para datos de entrenamiento y 20 % para evaluación).

Pero también existen otras técnicas como el cross-validation que intenta usar mejor los datos siguiendo los siguientes pasos:

- Se divide el corpus en k partes
- Se entrena en $k - 1$ partes y se evalúa en la restante
- Se repite para cada parte y se calcula el promedio.

Es recomendado que tanto los datos de entrenamiento como los de evaluación mantengan una igual distribución. Esto se puede lograr seleccionando entidades de forma aleatoria en el corpus siempre que el tamaño de una clase no sea muy inferior a las otras. Si ese es el caso, hay que incursionar en selecciones más estratificadas [8].

Cuando se trata de un problema de clasificación binaria en dos clases denominadas como + y -, cada instancia clasificada caerá dentro de algunos de los conjuntos definidos en el Cuadro 3.

	Clase	Predicción
Positivos verdaderos (TP)	+	+
Negativos verdaderos (TN)	-	-
Falsos positivos (FP)	+	-
Falsos negativos (FN)	-	+

Cuadro 1: Caracterización de los conjuntos para calcular medidas de performance en clasificación

Las medidas son:

- Accuracy: Fracción de las instancias clasificadas correctamente. Este tipo de medida no da los mejores resultados cuando el corpus está desbalanceado.
- Precisión: Se calcula mediante las instancias positivas que se clasificaron correctamente sobre el total de instancias que eran positivas ($TP / (TP + FP)$). Es decir que la precisión mide qué tan bueno es prediciendo una clase, no teniendo tanto en cuenta en cuáles se equivocó.
- Exhaustividad (recall): Fracción de las instancias positivas que se clasificaron correctamente sobre la fracción de instancias que son positivas ($TP / (TP + FN)$)
- Medida F1: Medida armónica entre precisión y recall. Se calcula como $2 * \text{precisión} * \text{recall} / (\text{precisión} + \text{recall})$.

Support Vector Machine

“Support Vector Machine” es un algoritmo de aprendizaje automático supervisado que utiliza un método discriminatorio, es decir que modela la clase directamente según los atributos y se puede utilizar tanto para problemas de clasificación como de regresión.

En este algoritmo, se traza cada elemento de datos como un punto en el espacio n -dimensional (donde n es el número de coordenadas del espacio donde están las entidades) con el valor de cada entidad como el valor de una coordenada en

particular. Luego, realiza la clasificación encontrando el hiperplano que diferencia claramente a las dos clases para después poder predecir.

Utilizando términos más intuitivos, observando la figura 3, los support vectors son H_1 y H_2 que son las dos entidades que pertenecen a clases distintas y están a menor distancia. El método busca la recta que maximiza el margen de distancia entre los support vectors.




Figura 3: SVM

2.2.2. Aprendizaje no supervisado:

En el aprendizaje no supervisado, los algoritmos no usan ningún dato etiquetado u organizado previamente para indicar cómo tendría que ser categorizada la nueva información, sino que tienen que encontrar la manera de clasificarlas ellos mismos. Por tanto, este método no requiere la intervención humana.

Un ejemplo de aprendizaje no supervisado es el clustering/agrupamiento, que es el proceso de particionar un conjunto de datos (u objetos) en un conjunto de subclases significativas llamadas grupos (clusters). Un grupo es una colección de objetos de datos que son similares a otros y así pueden ser tratados colectivamente como un grupo.

A diferencia de un caso supervisado, no se conocen las etiquetas de las clases (no hay clases predefinidas) y puede que tampoco se conozca el número de grupos.

Un buen método de agrupamiento produce grupos de alta calidad en los cuales la similitud dentro del grupo es alta y la similitud entre las clases es baja. La medida de similitud se define usualmente por proximidad en un espacio multidimensional [41].

2.3. Modelos de lenguaje

Un modelo de lenguaje es una distribución de probabilidad para un vocabulario específico que tiene como objetivo calcular la probabilidad de que ocurra una secuencia de palabras.

Estos modelos son muy usados para corrección de textos, procesamiento de habla, traducción, entre otros.

Actualmente es usual para esta tarea combinar Word embeddings con modelos de lenguaje neuronales como BERT, los cuales presentaremos a continuación.

2.3.1. Word embedding

Llamamos word embedding a la representación de una palabra en un vector numérico de dimensión N para análisis de textos. Se espera que cada vector capture distintas características de la palabra, logrando así que palabras que están semánticamente relacionadas y que se usan en contextos similares, se encuentren cerca en el espacio vectorial.

Muchos de los algoritmos de aprendizaje automático utilizan word embeddings como entrada para su procesamiento.

La representación en forma de vector de cada palabra va a depender del contexto en el que estas ocurren en un determinado corpus de texto.

Una de las formas más populares de convertir palabras a vectores es mediante la biblioteca creada por Facebook "fastText"[23]. Este modelo tiene distintos algoritmos para crear la representación vectorial de las palabras.

2.3.2. BERT

BERT (Bidirectional Encoder Representations from Transformers) es un modelo de lenguaje pre-entrenado por Google con un corpus gigantesco que ha tenido muy buenos logros últimamente en el área del PLN.

Es un modelo base que permite encontrar regularidades en grandes cantidades de texto que parecen ayudar a mejorar la performance en muchas tareas que usan lenguaje en general.

BERT es entrenado con dos estrategias:

- Modelo de Lenguaje Enmascarado (MLM): A diferencia de modelos de lenguajes más tradicionales que tienen como objetivo predecir la siguiente palabra en una secuencia, MLM predice las palabras enmascaradas teniendo en cuenta su contexto izquierdo y derecho.

El objetivo de MLM en BERT es calcular la distribución de probabilidad $p(\cdot | S \setminus \{w\})$ que es la probabilidad de que una palabra corresponda al espacio enmascarado en el enunciado S , donde la palabra w es la enmascarada.

- **Next Sentence Prediction (NSP, Predicción del Siguiente Enunciado):** El objetivo de NSP es predecir si de un par de enunciados S y S' , S' puede ser el siguiente enunciado de S . En el proceso de entrenamiento de BERT, el modelo recibe pares de enunciados como entrada y aprende a predecir si el segundo enunciado es subsecuente al primero en el documento original.

BERT ha logrado avances en el estado del arte de más de 11 tareas de procesamiento de lenguaje natural [15].

2.4. Evaluación de complejidad de textos

La evaluación de complejidad de textos refiere a qué tan fácil es para un lector entender el texto escrito.

Existen diferentes métricas para realizar esto, las cuales se complementan unas a las otras y miden distintas características de los textos.

2.4.1. Métricas de evaluación de texto

Las métricas de evaluación de texto se agrupan en distintos grupos, tales como:

Métricas tradicionales: Las métricas tradicionales para evaluar texto son aquellas que consideran atributos tales como el número de enunciados por texto, el promedio y máximo número de palabras por enunciado, el promedio de caracteres por palabras, y el promedio de sílabas por palabras.

Estas métricas tienen como objetivo clasificar textos en un determinado grado donde cada métrica utiliza una escala de valores distintos para cada grado.

Las técnicas mas conocidas son:

- **Smog index:**

Métrica desarrollada en 1969 por G. Harry McLaughlin [29].

Para calcular este índice, se deben seguir los siguientes pasos:

- Contar 10 enunciados cerca del comienzo, medio y final del texto a evaluar
- Contar cada palabra con más de 3 sílabas en todos los enunciados, sin importar si las palabras se repiten.
- Calcular la raíz cuadrada del número al que llegó en el paso anterior.
- Sumar 3 al resultado del paso anterior.

- **Flesch Kincaid Ease:**

Métrica desarrollada por la marina de los EEUU en los 1970's [25].

Se calcula como:

$$0,39\left(\frac{\#palabras}{\#enunciados}\right) + 11,8\left(\frac{\#sílabas}{\#palabras}\right) - 15,59 \quad (1)$$

■ **Coleman Liau Index:**

Métrica desarrollada en 1975 por Coleman y Liau [9].

Se calcula como:

$$0,0588\left(\frac{\#caracteres}{\#palabras}\right) * 100 - 0,296\left(\frac{\#enunciados}{\#palabras}\right) * 100 - 15,8 \quad (2)$$

■ **Automated Readability Index:**

Métrica desarrollada en 1967 por E.A. Smith y R.J. Senter [38].

Se calcula como:

$$4,71\left(\frac{\#caracteres}{\#palabras}\right) + 0,5\left(\frac{\#palabras}{\#enunciados}\right) - 21,43 \quad (3)$$

■ **Dale Chall Readability Score:**

Métrica creada en 1948 por Edgar Dale and Jeanne Chall donde se tenía una lista de 763 palabras simples la cual fue actualizada en 1995 por una lista de 3000 palabras simples. Si las palabras no se encuentran dentro de esta lista, son consideradas palabras complejas [12].

La lista está compuesta por lemas. A la hora de trabajar con esta métrica, se puede agrandar la lista teniendo en cuenta por ejemplo el plural de los sustantivos o los distintos tiempos verbales de cada verbo.

Se calcula como:

$$0,1579 * \left(\frac{\#palabras\ complejas}{\#palabras}\right) + 0,0496 * \left(\frac{\#palabras}{\#enunciados}\right) \quad (4)$$

■ **Linsear Write Formula:**

Métrica creada en 1966 por John O'Hayre [31].

Se calcula como:

- Obtener 100 palabras del texto
- Sumar 1 punto por las palabras fáciles (definidas como palabras de menos de 3 sílabas) y 3 puntos por las palabras complejas (de más de tres sílabas) y sumar todo
- Dividir el total por la cantidad de enunciados del texto

- Si el resultado de esta división es mayor a 20, dividir entre 2 y el resultado es el puntaje final. En otro caso, para obtener el resultado se debe restar 2 antes de dividir entre 2.

■ **Gunning Fog:**

Métrica desarrollada en 1952 por Robert Gunning Associates [20].

Se calcula como:

$$0,4\left[\left(\frac{\#palabras}{\#enunciados}\right) + 100\left(\frac{\#palabras\ complejas}{\#palabras}\right)\right] \quad (5)$$

Las palabras complejas son aquellas que contienen 3 o más sílabas.

Métricas léxicas: Estas métricas refieren a la estructura interna del vocabulario y la riqueza del texto.

Las técnicas más populares de esta categoría son:

- Basada en vocabulario: esta métrica se basa en vocabularios que contienen la información sobre cuáles palabras y frases es normal que los estudiantes ya tengan adquiridas en determinado nivel.

Un ejemplo de esta técnica podría aplicarse usando el English Vocabulary Profile (EVP) [16], diccionario con vocabulario específico para aprendices de segunda lengua, que utiliza los niveles de CEFR (detallados en Anexo A).

El EVP fue creado por el Cambridge Learner Corpus (CLC), que es una colección de exámenes escritos por estudiantes de alrededor del mundo. Esto provee una medida léxica compleja más refinada que captura la dificultad relativa de cada palabra asignándole una dificultad entre los seis niveles de CEFR.

- Proporción de presencia de palabras académicas, las cuales se podrían encontrar en listas como The Academic Word List (Coxhead, 2000).
- El porcentaje de palabras dentro de la categoría de significado léxico (sustantivos, verbos, adjetivos y adverbios) y palabras dentro de la categoría de significado funcional (todos los tipos de POS restantes) [43].
- Palabras únicas en el texto usando Type/Token Ratio (TTR): Refiere a la proporción entre el número de tipos (tokens únicos) y el número de tokens dentro de un texto. Como esto es sensible al largo del ejemplo, esta característica suele ser computada con textos de largo equivalente.

Métricas morfo-sintácticas: El objetivo de estas características es medir de alguna forma aspectos de la estructura lingüística que afectan de una manera u otra la complejidad del texto.

Estas características van desde la probabilidad de distribución de tipos de part-of-speech (categorías gramaticales) hasta la densidad léxica del texto, calculada como la proporción de palabras dentro de la categoría de significado léxico (sustantivos, verbos, adjetivos y adverbios) y el total de palabras.

Un ejemplo es la presencia de Modificadores: Un modificador hace referencia a palabras, frases o cláusulas que dan información sobre otra palabra en el mismo enunciado.

Ejemplo: "Voy al súper a comprar una hamburguesa vegetariana."
En este caso, *vegetariana* es un modificador.

Escala Lexile El *framework* Lexile es un enfoque científico que proporciona una guía para la medición de la comprensión lectora de una persona y la complejidad de un texto utilizando una misma escala (llamada escala Lexile).

El rango de esta escala es de 200L (principiantes) a 1500L (avanzados).

Esta escala es propiedad de MetaMetrics y su fórmula es privada. Sin embargo, se conoce que para la medición de la complejidad de un texto, se analizan características como el largo de los enunciados y la frecuencia de las palabras, similar a las métricas tradicionales. Enunciados largos y con palabras poco frecuentes tendrán un puntaje más alto en la escala Lexile [30].

El marco está desarrollado tanto para el inglés como para el español.

Esta escala es muy usada en escuelas, donde se realizan pruebas específicamente desarrolladas para obtener el puntaje Lexile de la comprensión lectora de los estudiantes. De esta forma los estudiantes pueden encontrar textos de puntaje similar al de su comprensión lectora. También es usada para evaluar textos en corpus como Newsela.

2.5. Trabajos relacionados

Previo a comenzar a desarrollar el proyecto se realizó una investigación de herramientas y recursos donde se aplican técnicas de PLN para la evaluación y simplificación de textos. El objetivo fue conocer cómo se está trabajando hoy en día en estas áreas, y qué enfoques han generado mejores resultados.

Un concepto importante que se utilizará en las siguientes secciones es el de Marco Común Europeo de Referencia (CEFR por sus siglas en inglés) [10]. El CEFR es un estándar que define niveles según lo que los estudiantes de idiomas comprenden en las diferentes etapas de su aprendizaje. Para esto se toma en cuenta las siguientes habilidades:

- Producción del habla
- Interacción en el habla
- Comprensión auditiva
- Lectura
- Escritura

CEFR describe seis niveles de dominio de la lengua, siendo A1 el más bajo y C2 el más alto. Los alumnos se clasifican en tres grupos distintos: el usuario básico (niveles A1 y A2), el usuario independiente (B1 y B2) y el usuario competente (C1 y C2).

En la Imagen 13 del Anexo A se puede visualizar qué se espera para cada nivel de esta escala.

2.5.1. Evaluación de complejidad

Lo primero que se quiso averiguar es qué tipo de métricas se usan actualmente para medir la legibilidad de un texto.

Estas métricas fueron vistas en detalle en la sección 2.4.1, pero a modo de repaso incluimos un resumen de las tres grandes categorías de métricas encontradas:

- **Tradicionales:** Consideran atributos tales como el número de enunciados por texto, el promedio y máximo número de palabras por enunciado, el promedio de caracteres por palabras, y el promedio de sílabas por palabras.
- **Léxico-semánticos:** Esta métrica evalúa tomando información de la simplicidad o dificultad del vocabulario usado en el texto.

- **Características sintácticas** Esta métrica evalúa aspectos de la estructura lingüística que afectan de una manera u otra la complejidad del texto.

Ya con un panorama más amplio de las distintas métricas existentes, se buscaron trabajos donde se evalúan estas métricas con el objetivo de encontrar cuál de ellas es más adecuada para la legibilidad de los textos.

A continuación se presentan distintos artículos, que trabajaron sobre evaluar textos en distintos idiomas, de los cuales se extrajo información valiosa para nuestro proyecto.

Evaluación de la legibilidad de los enunciados del italiano: ¿qué corpus y características? [13]

Con el objetivo planteado se generaron dos corpus: uno representativo de textos complejos extraídos del diario 'La Repubblica' y otro con textos simples extraídos de la revista 'Due Parole'. Luego, mediante un algoritmo de clasificación y selección de características basado en entropía máxima se identificó que las características tradicionales resultaron ser las características principales. Las características sintácticas tales como raíz verbal, profundidad de árbol, cadenas de cláusulas subordinadas embebidas y largo máximo de enlaces de dependencias también resultaron ser relevantes.

Clasificador automático de dificultad de texto [11]

Para este caso se utilizaron 237 textos a partir de exámenes y materiales de aprendizaje en portugués como corpus. Varios algoritmos de aprendizaje automático fueron puestos a prueba para clasificar la legibilidad de los textos.

Luego de eso, se aplicó un algoritmo de selección de características 'InfoGainAttributeEval' para detectar las características de mayor contribución.

Las que más influyeron en este análisis fueron:

- Cantidad de palabras
- Cantidad de palabras distintas
- Cantidad de nodos en el árbol
- Cantidad de enunciados

Enfoques basados en reglas y de aprendizaje automático para la legibilidad a nivel de enunciados en un segundo idioma [34]

Con el objetivo de proponer reglas para identificar la legibilidad de enunciados para el aprendizaje de sueco, se entrenó un método de clasificación supervisada

usando como corpus de entrenamiento y de prueba enunciados recolectados del corpus de CEFR escritos en sueco. Este corpus se dividió en dos clases, la clase a la que pertenecían los enunciados correspondientes al nivel B1 e inferiores, y la clase de los enunciados de un nivel más alto. Para este experimento, se obtuvieron ejemplos de modo de contar con las clases balanceadas en el corpus de entrenamiento.

Se experimentó con varios modelos, de los cuales el que mejor resultado obtuvo fue el clasificador Support Vector Machine (SVM).

Se tuvieron en cuenta 28 características distintas (léxicas, semánticas, sintácticas y tradicionales) pero las que más peso generaron a la hora de clasificar coinciden con las que toman características tradicionales y porcentajes de palabras complejas detectadas en el texto (léxicas).

Clasificación de palabras según su complejidad aplicando word embeddings

El objetivo del reporte [33] era el de experimentar con la aplicación de Word Embeddings para la clasificación de palabras según su grado de complejidad.

Para los experimentos, se construyó un corpus dividido en palabras simples y complejas, basado en la frecuencia de uso de las palabras.

Para las palabras simples, se utilizó el corpus de Simple Wikipedia[40], quitando stopwords y ordenando las palabras en orden ascendente según su frecuencia. Para el léxico se eligieron las 2190 palabras más frecuentes.

Para las palabras complejas, se utilizó una lista de 3990 palabras infrecuentes o complejas del idioma inglés, recopiladas a partir del sitio web [26].

Las palabras fueron representadas de forma vectorial utilizando Word2Vec con el corpus de GoogleNews.

El léxico final fue de 1960 palabras simples y 1952 palabras complejas.

Para la clasificación, se experimentó con un clasificador SVM y un clasificador Random Forest, donde se tenían dos clases: palabras simples y palabras complejas. Ambos clasificadores tuvieron resultados similares, aunque el SVM tenía la ventaja sobre el porcentaje de error (10 % contra 12 % de Random Forest). En estas condiciones, el clasificador SVM clasificó correctamente las palabras el 90 % de las veces.

2.5.2. Simplificación de textos

En este capítulo se presentan trabajos relacionados para las distintas áreas de simplificación de texto que se abordaron en este proyecto.

2.5.2.1. Simplificación léxica

La simplificación léxica (SL) tiene como objetivo reemplazar palabras complejas en un determinado enunciado con una alternativa simple con el mismo significado y sin modificar su estructura sintáctica.

En la Figura 4, podemos ver los pasos que se usan habitualmente para realizar sustituciones léxicas.




Figura 4: Pasos Simplificación Léxica, basado en la Figura 1 de [32]

1. **Identificación de Palabras Complejas:** tarea en la cual se decide qué palabras puedan no ser entendidas por el público objetivo y por ende deban ser simplificadas
2. **Generación de Candidatos de Sustitución:** tarea en la cual se buscan o generan palabras o expresiones que puedan reemplazar la palabra compleja objetivo
3. **Selección de Sustitutos:** tarea en la cual se decide cuál de las sustituciones candidatas generadas puede reemplazar a la palabra compleja sin comprometer la gramaticalidad o el significado del enunciado en un contexto dado
4. **Ranking de Sustitución:** tarea en la cual se clasifican las sustituciones candidatas restantes de la palabra compleja por su simplicidad

Este es un gran desafío ya que simplemente sustituir palabras puede generar textos incorrectos o poco naturales porque hay palabras que, aunque se puedan considerar sinónimos, no pueden intercambiarse en cualquier contexto.

Además, diferentes públicos objetivo tendrán necesidades distintas. Por ejemplo, hablantes de diferentes idiomas estarán más o menos familiarizados con diferentes subconjuntos del vocabulario de un segundo idioma [32]. Esto puede ayudar a varias personas, incluyendo niños y hablantes no nativos [35].

Los enfoques populares de simplificación léxica son:

- **Basados en reglas:** las cuales contienen diferentes tipos de reglas que asocian cada palabra compleja a un sinónimo más simple.

Los sistemas basados en reglas usualmente identifican sinónimos, utilizando recursos léxicos como WordNet, para un conjunto definido de palabras complejas, y seleccionan los más simples en base a la frecuencia o el largo de las palabras.

Estos sistemas necesitan mucho esfuerzo manual humano para definir sus reglas, y en la práctica es imposible generar reglas de modo que se cubran todos los casos posibles.

- **Basados en datos:** Existen corpus paralelos complejos y simples, por ejemplo derivados de Wikipedia y Simple Wikipedia (para el idioma inglés). Comparando los mismos textos en estos corpus, se pueden generar distintas reglas de simplificación. A modo de ejemplo, en [45] identificaron simplificaciones léxicas a partir del historial de edición de la Simple English Wikipedia.
- **Basados en Word-Embeddings:** Este enfoque consiste en generar posibles candidatos de sustitución calculando la similitud de las representaciones vectoriales de las palabras complejas (por ejemplo utilizando la similitud coseno). Un gran beneficio de este enfoque es que no requiere recursos léxicos o corpus paralelos como los anteriores.

A continuación se presenta un artículo que tomamos como referencia principal para este proyecto, donde se describe un proyecto de simplificación léxica en textos, del cual se extrajo información valiosa para nuestro proyecto.

Lexical Simplification with Pretrained Encoders [35]

BERT-LS es un enfoque de simplificación léxica que, haciendo uso de BERT, toma en cuenta tanto el enunciado entero como la palabra compleja a la hora de generar candidatos para sustituir la palabra [35].

Generación de candidatos: Para la generación de candidatos de sustitución de la palabra compleja, BERT-LS utiliza un modelo de lenguaje BERT-Large uncased, pre-entrenado con BooksCorpus e English Wikipedia [14].

BERT-LS hace uso del poder de predicción de BERT para generar candidatos de sustitución, quien hace uso de modelo de lenguaje enmascarado (MLM) y Next Sentence Prediction (NSP, Predicción del Siguiente Enunciado) como ya fue explicado en 2.3.2.

Siendo S el enunciado original, se enmascara la palabra compleja w con la etiqueta $[MASK]$, generando un enunciado S' .

S y S' son concatenados como un par de enunciados (S, S') antes de ser introducidos a BERT para dar uso del NSP, como se puede ver en la Figura 5.

Como salida se obtiene la probabilidad de distribución del vocabulario $p(\cdot | S, S \setminus \{w\})$ correspondiente a la palabra enmascarada.

Si el enunciado S' fuese introducido directamente en el modelo de lenguaje enmascarado (MLM), la probabilidad de distribución obtenida tendría en cuenta el contexto del enunciado pero la palabra compleja no tendría ningún peso ya que estaría enmascarada. De esta forma, las palabras con mayor probabilidad consideran tanto el contexto como la palabra compleja.

Finalmente, se seleccionan como candidatos de simplificación las 10 palabras donde la probabilidad es más alta, excluyendo las derivaciones morfológicas de w con un proceso de Stemming, que compara la raíz de la posible palabra candidata con la raíz de la palabra compleja.

En el ejemplo de la Figura 5 se observa que los candidatos encontrados mantienen el mismo significado que la palabra compleja, así como también la coherencia dentro del enunciado.




Figura 5: Generacion candidatos BERT

Si solo se hiciera uso de MLM sin tener en cuenta tambien NSP (teniendo como entrada solo un enunciado con la palabra compleja enmascarada), se podría tener algunos candidatos que pierdan el contexto original, como por ejemplo *"the cat died on the mat"*.

Ranking de sustitución Una vez generado los candidatos con BERT-LS, se estudian diversas características para cada candidato y luego se realiza un ranking para ver qué candidato es el mejor para sustituir la palabra compleja.

Las siguientes son las características que se utilizaron para evaluar los candidatos:

- **Orden de Predicción de BERT:** el candidato con mayor probabilidad calculada por BERT será el más relevante para el enunciado, ya que en el paso de generación de candidatos se tiene en cuenta información contextual
- **Modelo de lenguaje:** el candidato debería ajustarse a la secuencia de palabras precedentes y posteriores de la palabra original.

Para esto se siguen los siguientes pasos para cada palabra candidata:

- Reemplazar la palabra compleja por una palabra candidata
- Iterar el enunciado, excluyendo el candidato, siguiendo los siguientes pasos para cada palabra:
 - Sustituir palabra por *[MASK]*
 - Introducir el enunciado dentro del modelo de lenguaje enmascarado
 - Calcular pérdida de entropía cruzada
- Calcular el promedio de pérdida de entropía cruzada del enunciado.

El candidato con menor promedio de pérdida de entropía cruzada, será el que mejor se ajuste a sustituir la palabra compleja.

- **Similitud semántica:** Para esta característica, se utiliza un modelo de word-embeddings pre-entrenado de fastText [23] para representar de forma vectorial los candidatos y la palabra compleja. Se calcula la métrica de coseno de similitud entre el vector de la palabra compleja y la palabra candidata. El candidato con mayor similitud, será el que mejor se ajuste a sustituir la palabra compleja.

Puede suceder que la palabra compleja no pueda ser transformada a word-embedding. En ese caso, esta característica no es tenida en cuenta.

También puede suceder que el candidato no pueda ser transformado a word-embedding. En ese caso, la palabra candidata es descartada.

- **Frecuencia de aparición:** En general, las palabras que aparecen más frecuentemente, resultan ser más familiares para el lector.

Esta característica utiliza la escala Zipf [1], calculada como el $\log_{10}$ del resultado de apariciones en SUBTLEX (corpus constituido por más de seis millones de enunciados de subtítulos de películas), para ordenar los candidatos según su frecuencia.

- **Pertenece a la 'ParaPhrase DataBase' (PPDB)** PPDB es una base de datos que contiene millones de paraphrases (frases que escritas de distinta manera tienen el mismo significado cuando las traducimos a otro idioma) en 16 idiomas diferentes. El objetivo de esta base de datos es mejorar el

procesamiento de lenguaje haciendo sistemas más robustos a la variedad de palabras y a palabras desconocidas.

Esta característica verifica si para cada palabra candidata C_i y la palabra compleja w , existe un par (C_i, w) en la base PPDB. De así serlo, el peso de la característica en el candidato será más importante que aquellos que no pertenezcan.

Para finalizar se realiza un promedio entre todas estas características y se elige la de mayor puntaje como la indicada a reemplazar la palabra compleja.

2.5.2.2. Simplificación sintáctica

La simplificación sintáctica tiene como objetivo reducir la complejidad gramatical del texto conservando su significado.

El proceso consiste en reemplazar estructuras sintácticas (como pueden ser conjunciones) en enunciados para que el texto sea más fácil de leer. Por ejemplo, enunciados largos con conjunciones pueden ser divididos en dos enunciados más simples.

A continuación se describe un artículo que presenta reglas de simplificación para reemplazar estas estructuras sintácticas y generar enunciados más simples.

En el presente trabajo utilizamos este artículo como base para las transformaciones sintácticas (ver sección 4.3).

Syntactic simplification and Text Cohesion [39]

El objetivo principal del artículo es proveer un marco para la simplificación de textos, manteniendo la cohesión, a través de reglas sintácticas.

El artículo se basa en trabajos anteriores que hacen usos de métodos similares, entre ellos [7] quien define una teoría de dos etapas - análisis y transformación, el cual obtiene buenos resultados aunque no garantiza la cohesión del texto.

Para llegar al objetivo, el autor provee un método a seguir con tres partes principales, basadas en las dos etapas de [7], y agregando una tercera:

- **Análisis:** el texto es analizado para marcar constructores sintácticos que puedan ser simplificados.
- **Transformación:** el texto es transformado utilizando un conjunto de reglas manuales.
- **Regeneración:** se introducen palabras al texto generado para mantener la cohesión.

La etapa de análisis se encarga de las siguientes tareas: Part-of-speech tagging, identificación de cláusulas relativas y resolución de pronombres en tercera persona, a través de algoritmos presentados por el autor.

En esta etapa también se marcan los enunciados a ser simplificados. Para las reglas implementadas en el proyecto, se marcan enunciados con conjunciones y sus cláusulas.

Las cláusulas $Cláusula_n$ son definidas como cadenas de palabras del largo máximo posible, que contienen sujeto y verbo y que son divididas por algún token específico.

A continuación se muestran los patrones con los que debe coincidir un enunciado para ser marcado y consecuentemente simplificado.

Las cláusulas subordinadas que tienen como prefijo una conjunción deben coincidir con el siguiente patrón:

$$[Conjunción] \quad [Cláusula_1], \quad [Cláusula_2].$$

Las cláusulas son divididas por una coma y la *Conjunción* debe estar incluida en la siguiente lista de palabras para que el enunciado sea marcado para simplificar:

though, although, when, if, since, as o because.

Por ejemplo, el siguiente enunciado quedaría marcado de esta forma:

[*Conjunción* Although] [*Cláusula₁* both India and Pakistan announced partial troop withdrawals along the border], [*Cláusula₂* they both left their forces in Kashmir intact].

De manera similar, se marcan los enunciados con *If* como conjunción prefija que cumplen el siguiente patrón:

$$[If] \quad [Cláusula_1][(.) \text{ then}] \quad [Cláusula_2].$$

Es decir, la *Conjunción* es la palabra *if*, y las cláusulas son divididas por la palabra *then* (con una coma previa opcional).

Finalmente también son marcados los enunciados con conjunciones que coinciden con el siguiente patrón:

$$[Cláusula_1][(.) \text{ Conjunción}] \quad [Cláusula_2].$$

Para este caso, la *Conjunción* (con una coma previa opcional) es la que divide las cláusulas, y debe estar incluida en la lista de las siguientes palabras:

and, or, but, though, although, because, since, as, before, after o when.

Luego de analizados, los enunciados marcados pasan por la etapa de Transformación.

El autor declara siete reglas utilizadas para la etapa de Transformación. A continuación se presentan las tres reglas implementadas en este proyecto, aplicables para enunciados con cláusulas de conjunción (ver demás reglas en Anexo C):

En los ejemplos presentados, las palabras entre llaves corresponden a posibles palabras seleccionadas en la etapa de regeneración.

Reglas de Simplificación

La primera regla aplica para enunciados que tienen una conjunción como prefijo:

$$[Conjunción] \ [Cláusula_1], \ [Cláusula_2]. \rightarrow \ [Cláusula_1]. \ [Cláusula_2].$$

(Regla Simplificación 1)

En donde la *Conjunción* es una de las siguientes palabras: *though*, *although*, *when* o *because*.

Como ejemplo, esta regla divide el siguiente enunciado:

[*Conjunción* Although] [*Cláusula*₁ India announced troop withdrawals along the border], [*Cláusula*₂ their forces in Kashmir were left intact].

En:

[*Cláusula*₁ India announced troop withdrawals along the border]. {But} [*Cláusula*₂ their forces in Kashmir were left intact].

La segunda regla aplica para *if* como conjunción prefija y donde la división se realizaría si las cláusulas son unidas por *then* o una coma:

$$[If] \ [Cláusula_1] \ [then|,] \ [Cláusula_2]. \rightarrow \ [Cláusula_1]. \ [Cláusula_2].$$

(Regla Simplificación 2)

Ejemplo, divide:

[*Conjunción* If] [*Cláusula*₁ people have got in place proper effective safety measures], [*Conjunción* then] [*Cláusula*₂ naturally we are pleased about that].

En:

{Suppose} [*Cláusula*₁ people have got in place proper effective safety measures]. {Then} [*Cláusula*₂ naturally we are pleased about that].

La tercera regla aplica para enunciados donde la *Conjunción* es una de las siguientes palabras: *though, although, but, and, because, since, as, before, after* y *when*, y donde la coma es opcional.:

$$[Cláusula_1](,) [Conjunción] [Cláusula_2] \rightarrow [Cláusula_1]. [Cláusula_2].$$

(Regla Simplificación 3)

Ejemplo, divide:

[*Cláusula*₁ I have been involved with badgers for 24 years] [*Conjunción* and] [*Cláusula*₂ I have never heard of anything like this].

En:

[*Cláusula*₁ I have been involved with badgers for 24 years]. {And} [*Cláusula*₂ I have never heard of anything like this].

La etapa de regeneración intenta mantener la cohesión del texto introduciendo palabras (*cue-words*) para mantener la relación entre cláusulas conjuntas que hayan sido divididas. Se especifica una cue-word para cada conjunción transformada. En el ejemplo de la Regla Simplificación 1, se puede ver como *Although* introduce *But* (el resto de las cue-words introducidas por conjunción se pueden ver en el Cuadro 17 del Anexo C). Se seleccionan cue-words simples como *so* y *but* en vez de otros más complejos como *therefore* o *however*, siguiendo [42], donde se muestra que los lectores que están aprendiendo leían más rápido este tipo de palabras.

3. Evaluación de Textos

En este capítulo se describe el trabajo realizado para la evaluación de textos y la clasificación de palabras según su grado de complejidad.

Un concepto importante que se utilizará en las siguientes secciones es el de 'Grados K-12'. Estos grados son la forma de referirse en los sistemas educativos de Estados Unidos y Canadá al nivel escolar de los estudiantes, donde K hace referencia al Kindergarten (jardín de infantes) y 12 al último grado.

El trabajo está enfocado en los 'Grados K-5' (edades 4 a 11 de hablantes nativos).

3.1. Recopilación de corpus

Para probar las diferentes métricas de evaluación de textos, fue necesario encontrar numerosos textos en inglés en formato digital. Como no se contaba con textos propios, se realizó un relevamiento de corpus con textos en inglés, buscando especialmente que estuvieran clasificados según su complejidad.

A continuación se describen los corpus con los que se trabajó:

- Readworks es un sitio web que contiene cientos de textos en inglés clasificados por grado (K-12) y por la escala Lexile. Los textos son escritos por expertos y curados por educadores [22]. Se dividen en tres tipos: No-Ficción, Ficción y Poesía, y en tres categorías: Ciencia, Estudios Sociales y Arte [21].
- Newsela es un corpus introducido en [44] el cual contiene 1130 artículos de noticias, simplificados por editores profesionales. Cada artículo fue re-escrito manualmente varias veces para niños de diferentes grados. Estos grados abarcan de grado 2 a grado 12.

Uno de los objetivos de esta colección de textos es ayudar a profesores a preparar planes de estudio que coincidan con el nivel de inglés requerido en cada grado. La clasificación en los grados se basa en la escala Lexile. El corpus también cuenta con textos traducidos manualmente al español.

El corpus puede ser solicitado por socios académicos desde el sitio web. Desde el sitio también se tiene acceso a una colección en constante crecimiento de artículos con la posibilidad de ver el nivel de dificultad o complejidad de cada texto en un rango de varios niveles por artículo, así como también traducciones en español en cada nivel [44].

Junto al corpus, se obtiene también un archivo `articles_metadata.csv` con información sobre el idioma y el grado de los archivos correspondientes a cada artículo.

A continuación se presenta un mismo enunciado, que fue reescrito en distintos niveles como ejemplo de simplificación de Newsela

Texto Grado Alto: *When characters fly or fall through the sky in cartoons, they do all sorts of crazy things with clouds. They'll stand on clouds. They'll grab and eat clouds, or even wear the clouds like cotton balls. But what would it feel like to touch a cloud in real life?*

Texto Simplificado: *Cartoon characters do crazy things with clouds. They grab clouds. They wear clouds. They act like clouds are cotton balls. But what is it like to touch a cloud in real life?*

El primero obtuvo 830L en escala Lexile, y el simplificado obtuvo 450L en la misma escala. En la escala de grados K-12 esto corresponde a un grado 4 y 2 respectivamente.

- ISL (Internet Second Language) Collective es un sitio web donde profesores de lenguas extranjeras pueden compartir material de estudio de uso libre.

Los archivos son subidos en formato doc/docx y ppt/pptx.

El sitio permite filtrar entre diferentes tipos de materiales, vocabulario, tipo de estudiante (niños de jardín, escuela primaria, adultos) y niveles del texto (Pre-A1, A1, A2, B1, B2, C1, C2). Cabe destacar que el nivel del texto no está determinado por una escala automática, sino por los usuarios que suben los archivos al sitio.

Para Readworks e ISL, se realizaron scripts utilizando técnicas de web scraping para poder obtener y trabajar con los textos sin tener que descargarlos manualmente desde la página.

Web scraping hace referencia al proceso de obtener datos de páginas web de manera automática. Para la implementación de ambos script, se realizó parsing del Document Object Model de las páginas utilizando la biblioteca BeautifulSoup4 [36]. Para Readworks, fue necesario manejar la autenticación de un usuario, ya que los textos solo son accesibles para usuarios autenticados. En el caso de ISL también fue necesario simular un navegador web utilizando la biblioteca webbrowser [17], debido a limitaciones del sitio que no permitían la obtención del código de las páginas usando solicitudes HTTP.

Para Newsela, luego de haber solicitado permiso, se recibió un archivo comprimido con todos sus textos clasificados por grados.

En total se obtuvieron:

- Readworks: 3.425 textos distribuidos en 6 niveles.

- Newsela: 10.786 textos distribuidos en 11 niveles.
- ISL: 1.582 textos distribuidos en 6 niveles.

Una vez obtenidos todos los textos, se seleccionaron textos al azar y se evaluó cada uno bajo las fórmulas de métricas tradicionales utilizando la biblioteca *textstat*[6] para Python. Esta biblioteca, también calcula una métrica llamada *Text Standard*, la cual calcula un promedio utilizando todas las métricas tradicionales antes mencionadas. Esta fue la métrica a la cual se le dio más importancia en los análisis realizados.

En las gráficas que se muestran en este capítulo, se expone el resultado esperado para cada grado. Como se ve en las gráficas, esto depende de cada métrica. Por ejemplo, los textos de grado K de Readworks analizados con Smog Index tienen un valor de casi 6, mientras que los mismos textos analizados con Flesh Kincaid Grade tienen un valor un poco mayor a 2.

De los textos obtenidos en Readworks se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en la Figura 6.




Figura 6: Evaluación de Readworks con métricas

De los textos obtenidos en Newsela se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en la Figura 7.




Figura 7: Evaluación de Newsela con métricas

De los textos obtenidos en ISL Collective se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en la Figura 8.




Figura 8: Evaluación de ISL con métricas

Los resultados obtenidos se pueden ver en las figuras 18, 19 y 20 y en formato tabla en el Anexo E. Éstos fueron alentadores para la investigación, ya que los textos clasificados en grados más altos eran consistentes con valores más altos de las métricas, lo que daba un buen augurio sobre la utilidad de estas métricas a futuro.

La mayoría de las métricas mostraron consistencia entre el grado clasificado y el valor calculado, sin importar el corpus seleccionado.

Durante el proyecto, se le otorgó mayor influencia a la métrica *Text Standard* a la hora de analizar los resultados experimentales, ya que se basa en el promedio de todas las demás métricas.

3.2. Textos Ejemplo Desarrollados

A continuación se presentan 5 textos de ejemplo, obtenidos de Readworks, con los que se trabajará a lo largo del informe junto con el valor de las métricas para investigar las herramientas usadas.

Texto ejemplo 1:

“Have you ever seen a waterfall? A waterfall is a place in a river where water spills downward suddenly. Waterfalls can be big or small. They can be little, thin streams of water. They can also be huge and powerful! Iceland is an island country in the Atlantic Ocean. It has many waterfalls. One of its waterfalls is called Seljalandsfoss. “Foss” is the word for waterfall in Iceland. The water in Seljalandsfoss falls from almost 200 feet high. It lands in a pool below. But something about the way the water falls makes this waterfall special. It’s special because people can walk behind it! There is a cave behind the waterfall. Many people visit the waterfall and take a walk behind the water.”¹

Texto ejemplo 2:

““Why do I have to wake up so early?” Rosie asked. She rubbed her eye and looked out the window. It was still dark. Her dad was making pancakes. Rosie put on her jeans and a shirt. Then she ate her pancakes and was ready to go. Rosie’s dad drove to the river. They saw the sun come up in the sky. “Look at the sunrise,” Rosie said. She and her dad caught two fish. They ate lunch. Then they drove back home. Later that day, Rosie said to her dad, “Look at the sunset!” They saw the bright red sky. Rosie loved her day of fishing.”²

¹A Waterfall in Iceland: <https://www.readworks.org/article/A-Waterfall-in-Iceland/2355b133-2cfd-48e9-b64f-bb8599a7f02d>

²A Day for Fishing: <https://www.readworks.org/article/A-Day-for-Fishing/60d75061-2996-4bb7-82ce-d845213b29b5>

Texto ejemplo 3:

“Colonies are places ruled by a country far away. Long ago Britain had colonies in North America. People living in colonies are called colonists. In 1775, the colonists were not happy with Britain. They did not want to be ruled by Britain. They wanted to be their own country. The colonists decided to fight, so they collected weapons. Britain heard about the weapons. Britain wanted to take them away. The colonists learned that British soldiers wanted to take their weapons. They prepared to fight. They waited in a town called Lexington. The British soldiers arrived. Then someone fired a shot. Maybe it was a British soldier. Maybe it was a colonist. No one knows who fired it.”³

Texto ejemplo 4:

“Butterflies are beautiful insects. You often see them around colorful flowers. A butterfly’s life begins in a special way. First, a mother butterfly lays an egg on a leaf. A caterpillar hatches from the egg. The caterpillar eats leaves and grows bigger. Next, the caterpillar becomes a chrysalis (KRIS-a-liss). It makes a kind of hard shell that covers its whole body. During the time as a chrysalis, the caterpillar slowly changes. The parts of a butterfly begin to form, like the wings, legs, and antennae. Weeks or months later, a new creature pops out of the chrysalis shell. It has become a butterfly! The butterfly flutters its wings and flies away.”⁴

Texto ejemplo 5:

“I study a species of fish called the pacu. These fish are close vegetarian relatives of the meat-eating piranha. They are found in several rivers in South America.”⁵

³A Big Fight Begins: <https://www.readworks.org/article/A-Big-Fight-Begins/224f4461-3d60-4bdd-bf21-3b5efd078d43>

⁴A Butterfly’s Life: <https://www.readworks.org/article/A-Butterflys-Life/7a7ce4e1-6980-41cd-a728-15eefc6a0b52>

⁵Around the World with DNA: How to Avoid a Pacu Problem: <https://www.readworks.org/article/Around-the-World-with-DNA-How-to-Avoid-a-Pacu-Problem/0737d0cc-4b20-494e-b775-88cda2bab71a>

A continuación se muestran los resultados de las evaluaciones luego de evaluar las métricas sobre estos textos:

Métrica	Texto 1	Texto 2	Texto 3	Texto 4	Texto 5
Smog Index	8.6	3.1	6.5	8.8	10.5
Flesh Kincaid Grade	5.5	0.6	2.4	4.2	5.7
Coleman Liau Index	7.28	2.57	6.56	7.91	8.49
Automated Readability Index	5.0	1.3	4.6	6.0	6.3
Dale Chall Readability Score	6.26	5.37	6.81	8.18	8.61
Linsear Write Formula	4.08	3.17	3.0	4.55	5.33
Gunning Fog	4.82	3.28	4.47	4.84	8.01
Text Standard	5.93	2.77	4.9	6.35	7.56

Cuadro 2: Evaluación de Textos Ejemplo con métricas

3.3. Clasificar palabras según su grado de complejidad

En esta sección se tratará cómo se abordó el problema de clasificar palabras según su grado de complejidad en los textos. Es de nuestro interés identificar palabras complejas para cambiarlas por otra más simple que mantenga el significado del texto.

Algunas de las métricas de evaluación presentadas anteriormente toman en cuenta la cantidad de palabras simples y complejas que tiene el texto. También vimos que existe una técnica de evaluación basada en diccionario encontrada en el período de investigación (ver sección 2.4.1) que tiene esto en cuenta.

Se entrenó un clasificador de palabras según su complejidad para construir un evaluador basado en vocabulario aplicando Word Embeddings para la clasificación de palabras según su grado de complejidad.

Para el problema presentado, los objetos son las palabras y se tienen dos conjuntos de clases: palabras simples y complejas.

3.3.1. Recursos

Para construir esta herramienta, primero hubo que construir dos léxicos: uno con palabras que se consideran simples y otro con palabras complejas. Para esto, se utilizó el EVP [16], donde se tienen las palabras clasificadas según su grado de complejidad para hablantes de lenguas extranjeras.

También para el correcto funcionamiento de esta herramienta, fue necesario utilizar el lema de cada palabra, ya que el conjunto de datos es sacado de un diccionario.

Una vez obtenido el corpus, es necesario representar las palabras como vectores de palabras para poder utilizar los clasificadores de complejidad. Para ello se utilizó el modelo Word2Vec que ya fue preentrenado con el corpus de GoogleNews[18].

3.3.2. Clasificador

Se utilizó un modelo de clasificación “Support Vector Machine”. Para esta realidad las clases son: palabras simples (clase 0) y palabras complejas (clase 1), por lo que se trata de un clasificador binario.

Entonces, la entrada del algoritmo SVM viene dada por la representación vectorial de la palabra y su clasificación de complejidad.

En la etapa de preprocesamiento se utilizó AllenNLP para convertir las palabras a su lema e identificar las entidades con nombre de modo de no tenerlas en cuenta al momento de clasificar las palabras según complejidad. Esto es importante ya que estas palabras podrían ser identificadas como complejas y cambiar el sentido del enunciado.

También fue importante retirar del clasificador todas las palabras que estén dentro de comillas, ya que corresponden a citas que no deben ser alteradas en un texto.

Para poder evaluar el rendimiento del clasificador, se dividió el corpus separando el 80 % para datos de entrenamiento y 20 % para datos de evaluación del modelo de clasificación. El corpus final quedó constituido con las cantidades que se pueden ver en el Cuadro 5.

Se seleccionaron los elementos para cada conjunto de forma aleatoria en el conjunto de las palabras. Se consideró que aunque existe una porción más pequeña de palabras simples que de las complejas, no es tanta la diferencia como para buscar selecciones más estratificadas.

Como medida de evaluación del modelo de clasificación más significativo se decidió usar la medida F1, ya que Accuracy no se ajusta tan bien cuando se cuenta con un corpus un poco desbalanceado como es el que se tiene para esta realidad [8].

Observación:

Uno de los principales problemas al tratarse de un clasificador de dificultad por palabras es cuando hay que examinar palabras compuestas, o en inglés conocidas como multiwords, como por ejemplo los *phrasal verbs*. Puede suceder que la palabra por sí sola sea considerada fácil para el clasificador, pero cuando forma parte de un *phrasal verb*, resulta muy difícil para la comprensión de un estudiante inicial de segunda lengua. Detectar multiwords será un trabajo a futuro en este proyecto.

3.3.3. Experimentos

Una duda surgió a la hora de dónde colocar cada conjunto de palabras, estaba claro que A1 y A2 iban a ir para el conjunto de las simples, así como C1 y C2 para las complejas, pero qué pasaría con el resto era la principal interrogante.

Se colocó B2 en el conjunto de palabras complejas y se realizaron entrenamientos y evaluaciones con B1 dentro del conjunto de palabras simples, dentro del conjunto de palabras complejas, y fuera de los dos conjuntos.

Observando las métricas y los resultados se vio que el evaluador tiene mejores resultados cuando B1 está dentro del conjunto de palabras simples.

Las métricas obtenidas con B1 dentro del conjunto de palabras simples se puede ver en el siguiente Cuadro 3.

Accuracy	Medida F1	Precisión	Exhaustividad (recall)
0.79	0.84	0.78	0.9

Cuadro 3: Conjunto de clases: Experimento 1

A partir de aquí se siguió trabajando con las palabras pertenecientes a B1 dentro del conjunto de palabras simples.

Analizando los datos del vocabulario, se observó que había palabras que se encontraban en ambas categorías, debido a que existen palabras que en un contexto pueden ser A1 pero usada en otro contexto pueden ser un grado más alto en el EVP.

Esto también es un problema a la hora de realizar las evaluaciones, ya que como los conjuntos se definieron de forma aleatoria, puede ser que se esté evaluando sobre palabras que ya han sido clasificadas en el entrenamiento.

Para desambiguar esto, se decidió que si la palabra está en las dos categorías, se quitaría de las complejas y se dejaría solo en las simples.

Se volvieron a realizar las pruebas en el contexto mejorado, y como se puede ver en el Cuadro 4 las métricas finales bajaron un poco, pero se consideró este un escenario más realista.

Accuracy	Medida F1	Precisión	Exhaustividad (recall)
0.77	0.90	0.895	0.931

Cuadro 4: Conjunto de clases: Experimento

Con esta selección final en el corpus, cada clase quedó constituida por:

	Palabras Simples	Palabras Complejas
Corpus	3609	6500
Corpus Entrenamiento	2887	5200
Corpus Evaluación	722	1300

Cuadro 5: Cantidad de palabras por categoría

Se observa que existe una diferencia en la cantidad de palabras de los corpus que se consideró como aceptable debido a que el problema trata con un nivel escolar, donde la mayoría de palabras pueden ser consideradas complejas, ya que los estudiantes no cuentan aún con mucha experiencia en el idioma.

3.3.4. Resultados

Para los textos presentados en 3.2, se encontraron las siguientes palabras complejas:

Texto Ejemplo	Palabras Complejas
Texto 1	spills, downward, streams, powerful, lands
Texto 2	rubbed
Texto 3	ruled, colonies, colonists, collected, weapons
Texto 4	insects, colorful, lays, leaf, caterpillar, hatches, leaves, grows, chrysalis, shell, antennae, creature, become, flutters
Texto 5	species, pacu, relatives, piranha

Cuadro 6: Palabras complejas encontradas en los textos ejemplo

Luego de revisar las palabras complejas detectadas en los textos se realizaron las siguientes observaciones:

- Existen entidades con nombre muy raras ("*Seljalandsfoss*") las cuales el clasificador correctamente no las tomó en cuenta para clasificar.
- Palabras complejas entre comillas correctamente no fueron tenidas en cuenta al tratarse de citas que no se deberían modificar.
- Existen palabras compuestas las cuales por sí solas no serían complejas, pero al convertirse en compuesta sí, como es el caso de "*looked out*" en el texto 2, que el clasificador no la detectó como compleja, cuando se cree que debería.
- En el texto 5 es relevante observar la detección de *pacu* como palabra compleja. *Pacu* refiere a un tipo de pez específico que no debería ser sustituido para que el enunciado mantenga el sentido original.
- Algunas palabras detectadas como complejas se cree que pueden ser consideradas simples, tales como *leaves* o *leaf*

4. Simplificación de Textos

En este capítulo se describe la solución implementada para simplificar textos.

4.1. Sustitución léxica en palabras complejas con BERT-LS

Para poder hacer uso de este enfoque, se utilizó el algoritmo de clasificación de palabras complejas que se describe en 3.3. Esto es necesario debido a que el algoritmo de Sustitución léxica en palabras complejas con BERT-LS (Ver en 2.5.2.1) necesita como datos de entrada las palabras que se consideran complejas.

4.1.1. Experimentación

Los experimentos realizados sobre esta herramienta tuvieron como datos de entrada textos y las palabras complejas resultado de pre-procesar el texto anteriormente con el evaluador de palabras complejas.

La salida esperada de este algoritmo es el texto de entrada con la palabra compleja sustituida por una más simple luego de aplicar los algoritmos de BERT-LS (explicado en 2.5.2.1).

Luego de analizar varios textos, se observó que existían palabras que al ser sustituidas cambiaban su tiempo verbal o perdían el sentido del texto.

Estudiando el caso, se notó que esto estaba vinculado al tamaño de la ventana de contexto. Para algunos casos la ventana de contexto elegida era muy chica, por lo que BERT-LS no contaba con el contexto suficiente del enunciado al momento de seleccionar el sustituto de la palabra compleja, lo cual terminaba en cambios a palabras que perdían el sentido en el texto, o su tiempo verbal.

Para solucionar esto, se ejecutó el algoritmo varias veces con ventanas de contexto distintas con el fin de observar cuál es la que mejor se adapta. Teniendo en cuenta que al aumentar la ventana de contexto, el tiempo de ejecución de la tarea también iba aumentando, y teniendo en cuenta que se trabaja con cientos de textos, el aumento de tiempo puede llegar a ser muy relevante.

Finalmente, se decidió dejar una ventana de contexto de 60 palabras (30 hacia la izquierda y 30 a la derecha). Esta ventana de contexto no se limita solo al enunciado, si no que también puede llegar a tomar palabras del enunciado siguiente o anterior hasta llegar al límite de 30 palabras hacia la izquierda o derecha. Esto se hizo ya que luego de experimentar, se observó que tener un contexto mas abarcativo ayuda a obtener mejores resultados.

Se implementaron nuevas reglas gramaticales al algoritmo descrito anteriormente en 2.5.2.1: Utilizando pos-tagging (ver en 2.1.2), pudimos añadir como condición que si la nueva palabra a insertar es un verbo, debe ser igual al tiempo del verbo de la palabra a sustituir. De esta forma, se podría hacer un estudio más complejo, generando reglas para ayudar a la ventana de contexto limitada, teniendo en cuenta

qué tipo de categoría gramatical puede o no ser sustituida por otro tipo de categoría gramatical.

Como observación, es importante notar que, como el ranking de sustitución de BERT-LS depende del contexto, puede que una misma palabra sea sustituida por palabras distintas. Lo cual es algo positivo a la hora de querer siempre mantener el contexto.

4.1.2. Resultados

En esta sección, se pueden ver algunos resultados del algoritmo de BERT-LS modificado, el cual se encarga de convertir palabras complejas a otras más simples luego de aplicar su ranking de sustitución detallado anteriormente.

Se utilizaron las palabras complejas del clasificador de palabras según su grado de complejidad (ver sección 3.3) como entrada del algoritmo.

Una observación general luego de analizar los resultados es que, para algunas de las palabras que fueron detectadas como complejas, el algoritmo no encontró ningún sustituto más simple con la cual pudiera mantener el contexto. Por esta razón, algunas de las palabras se mantienen igual. Estas palabras son diferenciadas en color violeta en los siguientes ejemplos.

Ejemplo 1 Se realizaron las siguientes sustituciones léxicas:

“Have you ever seen a waterfall ? A waterfall is a place in a river where water spills forward (~~downward~~) suddenly. Waterfalls can be big or small. They can be little, thin lines (~~streams~~) of water. They can also be huge and strong (~~powerful~~) ! Iceland is an island country in the Atlantic Ocean. It has many waterfalls. One of its waterfalls is called Seljalandsfoss. “Foss” is the word for waterfall in Iceland. The water in Seljalandsfoss falls from almost 200 feet high. It lands in a pool below. But something about the way the water falls makes this waterfall special. It’s special because people can walk behind it ! There is a cave behind the waterfall. Many people visit the waterfall and take a walk behind the water.”⁶

Ejemplo 2 Se realizaron las siguientes sustituciones léxicas:

““Why do I have to wake up so early?” Rosie asked. She wiped (~~rubbed~~) her eye and looked out the window. It was still dark. Her dad was making pancakes. Rosie put on her jeans and a shirt. Then she ate her pancakes and was ready to go. Rosie’s dad drove to the river. They saw the sun come up in the sky. “Look at the

⁶A Waterfall in Iceland: <https://www.readworks.org/article/A-Waterfall-in-Iceland/2355b133-2cfd-48e9-b64f-bb8599a7f02d>

sunrise,” Rosie said. She and her dad caught two fish. They ate lunch. Then they drove back home. Later that day, Rosie said to her dad, “Look at the sunset!” They saw the bright red sky. Rosie loved her day of fishing.”⁷

Ejemplo 3 Se realizaron las siguientes sustituciones léxicas:

“Colonies are places **controlled** (~~ruled~~) by a country far away. Long ago Britain had **possessiones** (~~colonies~~) in North America. People living in **bases** (~~colonies~~) are called **settlers** (~~colonists~~) . In 1775, the **settlers** (~~colonists~~) were not happy with Britain. They did not want to be **controlled** (~~ruled~~) by Britain. They wanted to be their own country. The **citizens** (~~colonists~~) decided to fight, so they **collected** **guns** (~~weapons~~) . Britain heard about the **guns** (~~weapons~~) . Britain wanted to take them away. The **settlers** (~~colonists~~) learned that British soldiers wanted to take their **guns** (~~weapons~~) . They prepared to fight. They waited in a town called Lexington. The British soldiers arrived. Then someone fired a shot. Maybe it was a British soldier. Maybe it was a **captain** (~~colonist~~) . No one knows who fired it.”⁸

En el ejemplo 3 se observa que para algunas palabras se usa un sustituto distinto lo cual puede generar que se pierda el hilo de la narración. Esto es porque el ranking de sustitución de BERT-LS depende del contexto y para cada palabra se toma una ventana de contexto distinta.

Ejemplo 4 Se realizaron las siguientes sustituciones léxicas:

“Butterflies are beautiful **bugs** (~~insects~~) . You often see them around **beautiful** (~~colorful~~) flowers. A butterfly’s life begins in a special way. First, a mother butterfly **lays** an egg on a **plant** (~~leaf~~) . A **baby** (~~caterpillar~~) **releases** (~~hatches~~) from the egg. The **baby** (~~caterpillar~~) eats **leaves** and **becomes** (~~grows~~) bigger. Next, the **baby** (~~caterpillar~~) becomes a **shell** (~~chrysalis~~) (KRIS-a-liss). It makes a kind of hard **case** (~~shell~~) that covers its whole body. During the time as a **shell** (~~chrysalis~~) , the **baby** (~~caterpillar~~) slowly changes. The parts of a butterfly begin to form, like the wings, legs, and **arms** (~~antennae~~) . Weeks or months later, a new **thing** (~~creature~~) pops out of the chrysalis shell. It has **been** (~~become~~) a butterfly! The butterfly **flutters** its wings and flies away.”⁹

En el Ejemplo 4 se encontraron sustituciones, las cuales no se estuvo de acuerdo

⁷A Day for Fishing: <https://www.readworks.org/article/A-Day-for-Fishing/60d75061-2996-4bb7-82ce-d845213b29b5>

⁸A Big Fight Begins: <https://www.readworks.org/article/A-Big-Fight-Begins/224f4461-3d60-4bdd-bf21-3b5efd078d43>

⁹A Butterfly’s Life: <https://www.readworks.org/article/A-Butterflys-Life/7a7ce4e1-6980-41cd-a728-15eefc6a0b52>

pero se espera a futuro poder contar con un método que ofrezca las palabras sustitutas y permita elegir realizar la sustitución o quedarse con la palabra original.

Por ejemplo cuando se cambia *caterpillar* por *baby*, se cree que la sustitución es más simple pero también se pierde contexto.

La palabra *flutters* es detectada como compleja pero no se obtuvo una sustitución más simple, como podría haber sido *moves*.

Ejemplo 5 Se realizaron las siguientes sustituciones léxicas:

“ I study a kind (~~species~~) of fish called the tuna (~~pacu~~) . These fish are close vegetarian relatives of the meat-eating fish (~~piranha~~) . They are found in several rivers in South America.”¹⁰

En este ejemplo se observa que, si bien se soluciona la dificultad de las palabras complejas encontradas, "pacu" no debería haber sido cambiado.

En la siguiente tabla se muestra el resultado de evaluar con las métricas los textos:

Métrica	Texto 1	Texto 2	Texto 3	Texto 4	Texto 5
Smog Index	8.4 (-0.2)	3.1	5.9 (-0.6)	7.9 (-0.9)	9.7 (-0.8)
Flesh Kincaid Grade	5.5	0.6	1.3 (-1.1)	3.1 (-1.1)	4.6 (-1.1)
Coleman Liau Index	7.28	2.51 (-0.06)	6.85 (+0.29)	5.65 (-2.26)	7.28 (-1.21)
Automated Readability Index	4.9 (-0.1)	1.2 (-0.1)	4.8 (+0.2)	4.1 (-1.9)	5.3 (-1.0)
Dale Chall Readability Score	6.14 (-0.12)	5.37	6.54 (-0.27)	7.9 (-0.28)	7.48 (-1.13)
Linsear Write Formula	4.0 (-0.08)	3.17	2.86 (-0.14)	4.18 (-0.37)	5.0 (-0.33)
Gunning Fog	4.79 (-0.03)	3.28	3.79 (-0.68)	4.48 (-0.36)	6.58 (-1.43)
Text Standard	5.86 (-0.07)	2.75 (-0.02)	4.58 (-0.02)	5.33 (-1.02)	6.56 (-1.00)

Cuadro 7: Evaluación de Textos Ejemplo luego de simplificación léxica

Como se puede ver, comparando con el Cuadro 2:

¹⁰Around the World with DNA: How to Avoid a Pacu Problem: <https://www.readworks.org/article/Around-the-World-with-DNA-How-to-Avoid-a-Pacu-Problem/0737d0cc-4b20-494e-b775-88cda2bab71a>


- la mayoría de las métricas muestran una mejora aunque algunas empeoraron. La métrica Text Standard, usada como referencia, siempre bajó
- en textos de mayor nivel, las diferencias en las métricas son más grandes ya que son textos donde se realizan más sustituciones
- si bien se observa que las sustituciones léxicas transforman los textos en otros más simples, es razonable no ver cambios muy grandes con las métricas utilizadas ya que las sustituciones cambian una palabra por otra (lo que no varía la cantidad de palabras o la sintaxis del enunciado, pero sí el largo o cantidad de sílabas de la palabra)
- la métrica Dale-Chall que utiliza una lista de palabras simples para ser calculada siempre muestra una mejoría

4.2. Resolución de correferencias

Cuando se realizaron las simplificaciones manuales de los textos, se identificó la resolución de correferencias como una de las opciones para simplificar la legibilidad de un texto.

El objetivo es eliminar las correferencias de forma de quitar la ambigüedad (tal como la anafórica vista anteriormente en la sección 2.1) y ayudar en la lectura del texto, al no tener que razonar a qué hace referencia una expresión.

Para esto se utilizó el modelo de resolución de correferencias de AllenNLP [4]. Primero se resolvió el ejemplo propuesto para explicar la ambigüedad anafórica:



0 Margaret invited 1 Susan for a visit , and 0 she gave 1 her a good lunch .

Figura 9: Ejemplo resolución correferencia por AllenNLP

En la Figura 9 se observa que el modelo agrupa a 'Margaret' con 'she' y a 'Susan' con 'her'.

Se implementó un script para luego reemplazar las correferencias por su entidad original:

Antes: "Margaret invited Susan for a visit, and she gave her a good lunch."

Después: "Margaret invited Susan for a visit, and Margaret gave Susan a good lunch."

Esta herramienta pasó a formar parte de nuestro sistema. A continuación se presenta uno de los resultados obtenidos luego de ser aplicado a los textos.

Ejemplo:

"Have you ever seen a waterfall ? A waterfall is a place in a river where water spills forward suddenly. Waterfalls can be big or small. Waterfalls ~~(they)~~ can be little, thin lines of water. Waterfalls ~~(they)~~ can also be huge and strong! Iceland is an island country in the Atlantic Ocean. Iceland ~~(It)~~ has many waterfalls. One of Iceland ~~(It)~~ waterfalls is called Seljalandsfoss. "Foss" is the word for waterfall in Iceland. The water in one of Iceland waterfalls ~~(The water in Seljalandsfoss)~~ falls from almost 200 feet high." [2]

En el ejemplo, las correferencias resueltas son correctas y se opina que en general puede ser más simple para niños tener este tipo de ambigüedades resueltas, aunque el texto quedará más largo y redundante. Sin embargo, en el caso de la resolución de *Seljalandsfoss*, se cree que eliminar entidades con nombre puede perjudicar la comprensión y el sentido del texto.

4.3. Reglas Sintácticas

Tomando como base el artículo [39], descrito en la sección 2.5.2.2, se implementaron las reglas de simplificación 1, 2 y 3 relacionadas a las cláusulas coordinadas.

El objetivo es dividir enunciados largos en enunciados más cortos para simplificar la legibilidad del texto.

Como entrada del algoritmo, se tiene un texto el cual es dividido en enunciados y luego pasa por una etapa de análisis.

En esta primera etapa, se utilizó un modelo preentrenado de *elmo-constituency-parser* [5] de AllenNLP [4] para obtener un árbol sintáctico, que es necesario para analizar si es posible aplicar las reglas.

Las reglas implementadas fueron las siguientes (definidas en 2.5.2.2):

$$[Conjunción] [Cláusula_1], [Cláusula_2]. \rightarrow [Cláusula_1]. [Cláusula_2].$$

(Regla Simplificación 1)

$$[If] [Cláusula_1] [then|,] [Cláusula_2]. \rightarrow [Cláusula_1]. [Cláusula_2].$$

(Regla Simplificación 2)

$$[Cláusula_1](,) [Conjunción] [Cláusula_2] \rightarrow [Cláusula_1]. [Cláusula_2].$$

(Regla Simplificación 3)

Para cada enunciado del texto, se analiza si cumple con las condiciones de alguna de las reglas.

Para las reglas 1 y 2, primero se debe verificar que el primer token del enunciado corresponda a una conjunción, y que sea una de las palabras definidas en las reglas por el autor (ver 2.5.2.2): *though*, *although*, *when* o *because* (Regla Simplificación 1) o bien a la palabra *if* (Regla Simplificación 2). Como Penn Treebank[28] agrupa preposiciones y conjunciones subordinantes con la etiqueta *IN* (ver en Anexo D), se verifica que el token haya sido clasificado con esta etiqueta y que sea una de las palabras mencionadas.

Para la regla 3, se analiza el árbol de constituyentes en búsqueda de una palabra cuyo POS tag haya sido marcada como *CC* (conjunción coordinada) y que corresponda a una de las palabras definidas en 2.5.2.2: *though, although, but, and, because, since, as, before, after* o *when*.

Luego, para las tres reglas, si el enunciado cumple con la condición de alguna regla verificada hasta el momento, se proceden a analizar los árboles de constituyentes de las cláusulas para verificar si ambas contienen sujeto y verbo analizando si contienen POS tags *NP* y *VB*, *VBD*, *VBG*, *VCN*, *VBP* o *VBZ*.

Si el enunciado cumple con las verificaciones de alguna de estas reglas, se pasa a la etapa de transformación para aplicar la heurística correspondiente. En otro caso, se deja el enunciado sin modificar.

A modo de ejemplo, para el enunciado:

I have been involved with badgers for 24 years and I have never heard of anything like this.

El árbol de constituyentes obtenido por AllenNLP es:




Figura 10: Ejemplo de árbol de constituyentes

Primero se detecta la conjunción coordinada *AND*. Luego se recorren los árboles sintácticos de ambas cláusulas de conjunción.

Como ambas contienen una Noun Phrase (*NP*) y verbos, se aplicará la heurística para la división del enunciado.

Para el caso del enunciado:

Rose, Lily and Orchids are flowers.




Figura 11: Árbol de constituyentes del segundo ejemplo

Si bien se detecta una conjunción *AND*, en la Figura 11 se observa que el lado izquierdo no contiene verbo, por lo que la heurística no es aplicada.

En caso de aplicarse, se hubieran generado erróneamente los enunciados: “*Rose, Lily*” y “*Orchids are flowers.*”.

Luego de la etapa de análisis, si corresponde, se pasa a la etapa de transformación, donde se aplica la regla correspondiente. Para el caso de las reglas implementadas, esto requiere eliminar la conjunción, y dividir el enunciado en dos nuevos.

Ejemplo 1

I have been involved with badgers for 24 years and I have never heard of anything like this.

En este enunciado se aplica la Regla de Simplificación 3, la cual divide el enunciado en dos, eliminando la conjunción *and*:

I have been involved with badgers for 24 years. I have never heard of anything like this.

En la etapa de regeneración, se agregan las *cue-word* según la regla de transformación que fue aplicada, que en este caso reintroduce la palabra *And*.

La transformación final es:

I have been involved with badgers for 24 years. And I have never heard of anything like this.

Para algunos textos simplificados, se consideró que si la etapa de regeneración no fuera aplicada, los textos quedarían más simples al tener una palabra menos y aún mantendrían la cohesión. Por esta razón, la etapa de regeneración fue tratada como opcional a través de un parámetro de la herramienta. En el caso de no ejecutarse, el ejemplo anterior es transformado a:

I have been involved with badgers for 24 years. I have never heard of anything like this.

Ejemplo 2

Texto Original:

*If a dust storm comes, they will be prepared.*¹¹

Texto Transformado luego de aplicar la Regla de Simplificación 2:

Suppose a dust storm comes. Then they will be prepared.

Si no se le aplica la etapa de regeneración, el resultado sería:

If a dust storm comes. They will be prepared.

Si los resultados de la implementación fueran luego analizados por un humano con nivel avanzado de inglés, se podría analizar si el texto pierde demasiada cohesión (como en el caso del segundo enunciado) o si queda aún más simple para el público objetivo cuando la etapa de regeneración no es aplicada.

Ejemplo 3

Texto Original 1:

*Cleopatra became queen when she was 18 years old.*¹²

Texto Transformado 1 luego de aplicar la Regla Simplificación 3:

Cleopatra became queen. She was 18 years old.

¹¹Be Ready for Dust Storms: <https://www.readworks.org/article/Be-Ready-for-Dust-Storms/56059d4c-8ed7-4f6e-a39f-4ca9449f72a7>

¹²Cleopatra: <https://www.readworks.org/article/Cleopatra/c890e591-8953-4636-8450-9a84610bf55b>

Texto Original 2:

*The two had fought terribly when they tried to share the land.*¹³

Texto Transformado 2 luego de aplicar la Regla Simplificación 3:

The two had fought terribly. They tried to share the land.

En este ejemplo se muestran dos enunciados donde la conjunción es la palabra *when*. El primer texto mantiene su sentido. En el otro, la misma conjunción conlleva a una pérdida de cohesión del texto.

Ejemplo 4

Texto Original:

*Recently the wild populations have been overfished, and their numbers are decreasing.*¹⁴

Texto Transformado:

Recently the wild species have been exploited. Their numbers are decreasing.

En este ejemplo primero fue aplicada la sustitución léxica (desarrollada en 4.1) y la Regla de Simplificación 3 al texto original.

¹³The Story of Rome: <https://www.readworks.org/article/Ancient-Rome-and-Byzantium---The-Story-of-Rome/559b579c-bdcc-4e45-b6d4-66913226764b>

¹⁴Around the World with DNA: How to Avoid a Pacu Problem : <https://www.readworks.org/article/Around-the-World-with-DNA-How-to-Avoid-a-Pacu-Problem/0737d0cc-4b20-494e-b775-88cda2bab71a>

5. Experimentación

Para experimentar con la implementación de los módulos de evaluación y simplificación, se realizó el siguiente experimento:

1. Tomamos 100 textos por grado extraídos de ReadWorks.
2. Calculamos sus grados iniciales con las herramientas de evaluación, con foco en la métrica de Text Standard (promedio de las demás).
3. Sumamos el grado de todos y los dividimos por la cantidad de textos en cada nivel.
4. Simplificamos los textos con nuestras herramientas.
5. Volvimos a calcular el grado obtenido de los textos luego de simplificar y luego dividimos por la cantidad de textos (igual cantidad de textos que en paso 2, ya que son los mismos)

Las pruebas se realizaron sobre los textos extraídos de Readwork, que cuenta con los niveles: K, 1, 2 , 4 y 5. Donde K corresponde al grado mas simple.

Cuando se experimentó con los módulos por separado se obtuvieron los siguientes resultados:

Módulo de simplificación léxica con BERT-LS: En el siguiente cuadro, se podrá ver la diferencia de valores de los textos iniciales y finales, con la medida Text Standard luego de solo simplificar con BERT-LS.

Métrica Text Standard	Valor inicial	Valor final	Dif
Grado K	3.91	3.87	-0.04
Grado 1	4.56	4.46	-0.10
Grado 2	6.18	6.05	-0.13
Grado 3	6.79	6.42	-0.37
Grado 4	8.07	7.48	-0.59
Grado 5	9.11	8.25	-0.86

Cuadro 8: Diferencias en Text Standard en BERT-LS

Módulo de reglas de simplificación sintáctica: En el siguiente cuadro, se podrá ver la diferencia de valores de los textos iniciales y finales, con la medida Text Standard luego de solo aplicar las reglas de simplificación sintáctica.

Métrica Text Standard	Valor inicial	Valor final	Dif
Grado K	3.91	3.84	-0.07
Grado 1	4.56	4.34	-0.22
Grado 2	6.18	5.93	-0.25
Grado 3	6.79	6.25	-0.54
Grado 4	8.07	7.34	-0.73
Grado 5	9.11	8.08	-1.03

Cuadro 9: Diferencias en métrica Text Standard

Se observa que el módulo de reglas de simplificación sintáctica genera una diferencia en los valores de las métricas más amplia. Esto se debe a que los cambios sintácticos en el texto generados por las reglas de simplificación influyen más por la forma en la cual las métricas de evaluación se calculan. Por ejemplo, el cambio de una palabra compleja a simple puede influir en la cantidad de sílabas de una oración pero no en el largo, como es el caso de las reglas.

Luego para experimentar de forma global, se unieron los dos módulos y se obtuvieron los siguientes resultados evaluados en todas las métricas estudiadas, presentados en los siguientes cuadros:

Grado K:

Métrica	Valor inicial	Valor final
Smog Index	5.62	5.48
Flesh Kincaid Grade	2.27	2.39
Coleman Liau Index	4.94	4.3
Automated Readability Index	3.4	2.81
Dale Chall Readability Score	3.57	3.29
Linsear Write Formula	3.15	3.1
Gunning Fog	3.9	3.7
Text Standard	3.91	3.81

Cuadro 10: Readworks grado K

Grado 1:

Métrica	Valor inicial	Valor final
Smog Index	6.23	6.08
Flesh Kincaid Grade	3.03	3.13
Coleman Liau Index	5.67	5.08
Automated Readability Index	4.28	3.69
Dale Chall Readability Score	4.39	4.31
Linsear Write Formula	3.94	3.74
Gunning Fog	4.48	4.15
Text Standard	4.56	4.28

Cuadro 11: Readworks grado 1

Grado 2:

Métrica	Valor inicial	Valor final
Smog Index	7.53	6.43
Flesh Kincaid Grade	4.98	4.93
Coleman Liau Index	8	6.94
Automated Readability Index	6.92	5.68
Dale Chall Readability Score	5.92	5.26
Linsear Write Formula	5.85	5.39
Gunning Fog	6.31	5.74
Text Standard	6.18	5.89

Cuadro 12: Readworks grado 2

Grado 3:

Métrica	Valor inicial	Valor final
Smog Index	7.37	6.31
Flesh Kincaid Grade	5.01	4.88
Coleman Liau Index	7.74	6.33
Automated Readability Index	6.81	5.16
Dale Chall Readability Score	5.58	5.47
Linsear Write Formula	5.81	5.25
Gunning Fog	6.41	5.69
Text Standard	6.79	5.71

Cuadro 13: Readworks grado 3

Grado 4:

Métrica	Valor inicial	Valor final
Smog Index	9.13	7.25
Flesh Kincaid Grade	8.51	6.53
Coleman Liau Index	9.37	8.31
Automated Readability Index	11.02	7.26
Dale Chall Readability Score	6.73	6.28
Linsear Write Formula	9.71	6.57
Gunning Fog	10.19	7.22
Text Standard	8.07	6.88

Cuadro 14: Readworks grado 4

Grado 5:

Métrica	Valor inicial	Valor final
Smog Index	11.72	6.77
Flesh Kincaid Grade	8.46	6.96
Coleman Liau Index	11.72	8.45
Automated Readability Index	11.29	7.81
Dale Chall Readability Score	7.22	6.49
Linsear Write Formula	8.79	7.51
Gunning Fog	9.82	7.66
Text Standard	9.11	7.78

Cuadro 15: Readworks grado 5

En el siguiente cuadro, se podrá ver la diferencia de valores de los textos iniciales y finales, con la medida Text Standard.

Métrica Text Standard	Valor inicial	Valor final	Dif
Grado K	3.91	3.81	-0.1
Grado 1	4.56	4.28	-0.28
Grado 2	6.18	5.89	-0.29
Grado 3	6.79	5.71	-1.08
Grado 4	8.07	6.88	-1.19
Grado 5	9.11	7.78	-1.33

Cuadro 16: Diferencias en métrica Text Standard

Las pruebas se realizaron en una computadora con procesador AMD Ryzen 5 3600 de 6 núcleos de 3.6GHz, 16GB de memoria RAM y tarjeta de video Nvidia 1070. En estas condiciones los tiempos en promedio de ejecutar el algoritmo completo para cada nivel fueron los siguientes:




Figura 12: Tiempo de ejecución por Grado

Los resultados del experimento fueron:

- En todos los grados evaluados, la medida Text Standard, que es la medida que se usó como referencia, fue más baja. Mostrando que en promedio los textos fueron simplificados.
- En niveles bajos, no todas las métricas muestran esta mejoría, por ejemplo Flesch Kincaid Grade recién mejora su medida a partir del grado 2. Esto puede ser esperable, ya que esos textos tienen que ser los más simples de por sí, así que el efecto de simplificarlos debe ser muy leve.
- En el Cuadro 16 se observa que cuanto más alto es el grado (y más complejo el texto), mayor es la diferencia de simplificado según las métricas. Esto se atribuye a la cantidad de palabras complejas incluidas y léxico más variado, con estructuras gramaticales más avanzadas.
- En niveles más altos, el tiempo que se demora en correr el algoritmo es mayor, debido a la inclusión de más palabras complejas y el largo del texto.

6. Conclusiones y Trabajo Futuro

En esta sección se detallan las conclusiones obtenidas luego de realizar el proyecto y se presentan diferentes propuestas de trabajo a futuro, con el fin de continuar mejorando lo realizado.

6.1. Conclusiones

En este proyecto, que busca generar contenido de lectura para niños en etapa escolar acorde a su nivel de comprensión, se implementó una herramienta que tiene el potencial para clasificar textos según su complejidad y simplificarlos en caso de ser necesario.

Para poner a prueba nuestra herramienta, se extrajeron grandes cantidades de textos de distintas fuentes clasificados por profesionales según su complejidad.

Se investigaron diferentes métricas de evaluación, que son utilizadas para evaluar textos en la práctica, tanto en ámbitos educativos como de investigación.

Se evaluaron los textos clasificados por nivel con las métricas de evaluación investigadas. Se notó que las métricas mostraban un resultado correlativo con el nivel de complejidad. Si bien todas las métricas mostraban la correlación, se decidió trabajar principalmente con la métrica Text Standard, la cual obtiene un promedio de éstas, de forma de que todas tengan un peso en el resultado final, aunque también se mostraron los resultados de las otras métricas de interés.

Si un texto no es lo suficientemente simple para poder ser utilizado como recurso educativo, se estudiaron técnicas para poder simplificarlo.

Como primer paso, se investigó acerca de la simplificación léxica: la identificación y sustitución de palabras complejas por palabras simples. Para esto, se aplicaron Word Embeddings y se entrenó un clasificador SVM basados en un vocabulario para detectar las palabras complejas, y luego se utilizó el enfoque de BERT-LS para la generación y selección de los sustitutos.

Finalmente, se aplicaron reglas sintácticas de simplificación para reducir la complejidad de enunciados.

Para poner a prueba los resultados de la simplificación, se evaluaron los textos antes y después de simplificar y se compararon los resultados con las medidas de evaluación que anteriormente clasificamos como fiables (habiéndolas comparado contra los textos originales).

En estos resultados se observó que los textos generados son más simples basándose en las métricas utilizadas, especialmente en grados de más alto nivel, donde se encuentran incluidas una mayor cantidad de palabras complejas y léxico más variado, con estructuras gramaticales más complejas. Sin embargo, al observar el contenido de los textos simplificados, se observó que en algunos casos, los textos pierden coherencia e incluso el tiempo verbal como vimos en los ejemplos 3 y 4 en

los resultados de experimentos de simplificación con BERT-LS 4.1.2.

Por esta razón, si bien esta herramienta puede ser usada como soporte para la enseñanza de inglés a nivel escolar, se recomienda que una vez utilizada, los resultados sean revisados manualmente por personas con buen nivel de inglés.

6.2. Trabajo a futuro

A continuación se presentan ideas y posibles mejoras a realizar para la herramienta implementada.

Implementación de más reglas de evaluación En los artículos estudiados de evaluación se presentan otras técnicas de evaluación que toman en cuenta características sintácticas, léxicas y semánticas. Debido al alcance del proyecto no fueron incluidas y se trabajó con características de evaluación más tradicionales que, en los artículos estudiados, mostraban que tenían un mayor peso.

Implementación de más reglas de simplificación En el artículo estudiado para la simplificación de enunciados a través de reglas de simplificación [39], se presentan reglas para cláusulas relativas y expresiones apositivas que no fueron implementadas. Estas reglas pueden resultar de interés para corpus como Newsela, que están basados en artículos de noticias, donde son frecuentes este tipo de expresiones.

Eliminación de información innecesaria Una de las características observadas por las traducciones manuales de los estudiantes de la FIC fue la de eliminación de información innecesaria. Se podría utilizar la resolución de correferencias para eliminar enunciados donde un sujeto se presente por una única vez en el texto, o investigar los métodos utilizados para sintetizar automáticamente textos.

Herramienta interactiva Actualmente la herramienta modifica todas las palabras complejas por la palabra que se encuentra mejor posicionada en el ranking de sustitución de BERT-LS.

Se cree que una mejora para la herramienta es poder seleccionar cuáles de las palabras complejas se quieren sustituir, y luego si alguna sustitución no es considerada adecuada, tener la opción de conservar la anterior o ver otras sugerencias de palabras para sustituir.

Experiencia con usuarios reales Debido a la pandemia que enfrentó el país cuando se desarrollaba este proyecto, no se pudo tener la experiencia de que la herramienta fuera utilizada por usuarios reales en las escuelas rurales. Es por esto

que quedó pendiente ver en la práctica a qué grado real pertenecen los valores de Text Standard. Los niños deberían trabajar con los textos que esta medida sugiere para generar una retroalimentación para la herramienta.

Mejoras en el estado del arte del PLN El Procesamiento de Lenguaje Natural (PLN) está en constante desarrollo y frecuentemente se publican nuevos artículos con técnicas de simplificación.

Sería interesante seguir estudiando el desarrollo de esta disciplina, para poder implementar nuevas técnicas que mejoren la herramienta generada.

Referencias

- [1] “A critical evaluation of current word frequency norms and the introduction of a new and improved word frequency measure for American English.” En: (). <https://doi.org/10.3758/BRM.41.4.977>.
- [2] *A Waterfall in Iceland* AssignPrint. <https://www.readworks.org/article/A-Waterfall-in-Iceland/2355b133-2cfd-48e9-b64f-bb8599a7f02d#!articleTab:content/>, author=Readworks.
- [3] *ANEP: Ingles sin limite*. <https://www.anep.edu.uy/codicen/politicas-linguisticas/focus-on-first>.
- [4] The Allen Institute for Artificial Intelligence. *AllenNLP*. 2021. URL: <https://allenai.org/allennlp> (visitado 12-12-2021).
- [5] The Allen Institute for Artificial Intelligence. *AllenNLP Models*. 2022. URL: <https://github.com/allenai/allennlp-models>.
- [6] Shivam Bansal. *textstat*. <https://github.com/shivam5992/textstat>. 2020.
- [7] Raman Chandrasekar y Bangalore Srinivas. “Automatic Induction of Rules for Text Simplification”. En: 1997. DOI: 10.1016/S0950-7051(97)00029-4.
- [8] “Clasificación”. En: (). https://eva.fing.edu.uy/pluginfile.php/256847/mod_resource/content/1/INTROPLN%20-%20M%C3%A9todos%20de%20Clasificaci%C3%B3n.pdf.
- [9] M. Coleman, Liao y T. L. “A computer readability formula designed for machine scoring. Journal of Applied Psychology”. En: (1975). <https://doi.org/10.1037/h0076540>.
- [10] “Common European Framework of Reference”. En: (). <https://www.englishprofile.org/images/pdf/GuideToCEFR.pdf>.
- [11] Pedro Curto, Nuno J. Mamede y J. Baptista. “Automatic Text Difficulty Classifier - Assisting the Selection Of Adequate Reading Materials For European Portuguese Teaching”. En: *CSEDU*. 2015. URL: <https://www.inesc-id.pt/publications/11043/pdf>.
- [12] E. y Chall J. S. Dale. *A formula for predicting readability*. 1948.
- [13] Felice Dell’Orletta y col. “Assessing the Readability of Sentences: Which Corpora and Features?” En: jun. de 2014. DOI: 10.3115/v1/W14-1820.
- [14] Jacob Devlin y col. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. En: *CoRR* abs/1810.04805 (2018). arXiv: 1810.04805. URL: <http://arxiv.org/abs/1810.04805>.

- [15] Jacob Devlin y col. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. En: (2019). <https://arxiv.org/pdf/1810.04805.pdf>.
- [16] *English Vocabulary Profile*. <https://www.englishprofile.org/wordlists>.
- [17] Python Software Foundation. *Python’s webbrowser*. <https://docs.python.org/3/library/webbrowser.html>. 2020.
- [18] Google. *GoogleNews Word2Vec*. <https://code.google.com/archive/p/word2vec/>. 2013.
- [19] “Gramáticas Formales”. En: (). https://eva.fing.edu.uy/pluginfile.php/155793/mod_resource/content/0/GFLN2017_01_intro.pdf.
- [20] R. Gunning. *The Technique of Clear Writing*. McGraw-Hill, 1952. ISBN: 9787000014190. URL: <https://books.google.com.uy/books?id=ofIOAAAAAAAJ>.
- [21] ReadWorks Inc. *ReadWorks*. 2021. URL: <https://web.archive.org/web/20211119230135/https://www.readworks.org/> (visitado 19-11-2021).
- [22] ReadWorks Inc. *ReadWorks About Page*. 2021. URL: <https://web.archive.org/web/20200828160420/https://about.readworks.org/about.html> (visitado 28-08-2020).
- [23] Armand Joulin y col. “FastText.zip: Compressing text classification models”. En: *arXiv preprint arXiv:1612.03651* (2016).
- [24] Dan Jurafsky y James H. Martin. *Speech and language processing: an introduction to natural language processing, computational linguistics, and speech recognition, 2nd Edition*. Prentice Hall series in artificial intelligence. Prentice Hall, Pearson Education International, 2009. ISBN: 9780135041963.
- [25] J. Peter Kincaid y col. “Derivation of New Readability Formulas (Automated Readability Index, Fog Count and Flesch Reading Ease Formula) for Navy Enlisted Personnel”. En: 1975.
- [26] Thomas Kung. *Complex English Vocabulary*. 2018. URL: <https://quizlet.com/hk/257200583/complex-english-vocabulary-flash-cards/>.
- [27] Mirella Lapata. *Talk to me in plain English, please! Explorations in Data-driven Text Simplification*. 2011. URL: https://videlectures.net/esslli2011_lapata_simplification/.
- [28] Mitchell P. Marcus, Beatrice Santorini y Mary Ann Marcinkiewicz. “Building a Large Annotated Corpus of English: The Penn Treebank”. En: *Computational Linguistics* 19.2 (1993), págs. 313-330. URL: <https://aclanthology.org/J93-2004>.

- [29] Harry G. McLaughlin. “SMOG grading - a new readability formula”. En: *Journal of Reading* (mayo de 1969), págs. 639-646.
- [30] MetaMetrics. *Lexile Scale*. <https://metametricsinc.com/education-companies/lexile-for-reading-and-writing/about-lexile-for-reading/>. 2020.
- [31] John O’Hayre. *Gobbledygook Has Gotta Go*. 1965.
- [32] Gustavo H. Paetzold y Lucia Specia. “A Survey on Lexical Simplification”. En: *Journal of Artificial Intelligence Research* 60 (2017), págs. 549-593. DOI: 10.1613/jair.5526.
- [33] Universidad de la República Percovich A. Reporte Interno del Grupo PLN Instituto de Computación. *Clasificación de palabras según su complejidad aplicando word embeddings*. 2018.
- [34] Ildikó Pilán, Elena Volodina y Richard Johansson. “Rule-based and machine learning approaches for second language sentence-level readability”. En: jun. de 2014. DOI: 10.3115/v1/W14-1821.
- [35] Jipeng Qiang y col. “Lexical Simplification with Pretrained Encoders”. En: *Thirty-Fourth AAAI Conference on Artificial Intelligence* (2020), págs. 8649-8656.
- [36] Leonard Richardson. *BeautifulSoup4*. <https://www.crummy.com/software/BeautifulSoup/>. 2020.
- [37] Sebastian Ruder. *NLP-progress*. 2020. URL: <http://nlpprogress.com/english/simplification.html>.
- [38] RJ Senter y Edgar A Smith. *Automated readability index*. Inf. téc. Cincinnati Univ OH, 1967.
- [39] Advait Siddharthan. *Syntactic simplification and Text Cohesion*. English. Technical Reports 597. University of Cambridge, oct. de 2004.
- [40] *Simple Wikipedia*. 2018. URL: https://en.wikipedia.org/wiki/Wikipedia:Database_download.
- [41] Jesús Cáceres Tello. *Reconocimiento de patrones y el aprendizaje no supervisado*.
- [42] Sandra Williams, Ehud Reiter y Liesl Osman. “Experiments with discourse-level choices and readability”. En: *Proceedings of the 9th European Workshop on Natural Language Generation (ENLG-2003) at EACL 2003*. Budapest, Hungary: Association for Computational Linguistics, abr. de 2003. URL: <https://aclanthology.org/W03-2317>.

- [43] Menglin Xia, Ekaterina Kochmar y Ted Briscoe. “Text Readability Assessment for Second Language Learners”. En: ene. de 2016, págs. 12-22. DOI: 10.18653/v1/W16-0502. URL: https://www.researchgate.net/publication/306093769_Text_Readability_Assessment_for_Second_Language_Learners.
- [44] Wei Xu, Chris Callison-Burch y Courtney Napoles. “Problems in Current Text Simplification Research: New Data Can Help”. En: (2015). DOI: 10.1162/tac1_a_00139.
- [45] Mark Yatskar y col. “For the sake of simplicity: Unsupervised extraction of lexical simplifications from Wikipedia”. En: *Human Language Technologies: The 2010 Annual Conference of the North American Chapter of the Association for Computational Linguistics*. Los Angeles, California: Association for Computational Linguistics, jun. de 2010, págs. 365-368. URL: <https://aclanthology.org/N10-1056>.

Anexos:

A. CEFR Levels

C2	• Can understand with ease virtually everything heard or read. • Can summarise information from different spoken and written sources, reconstructing arguments and accounts in a coherent presentation. • Can express him/herself spontaneously, very fluently and precisely, differentiating finer shades of meaning even in more complex situations.
C1	• Can understand a wide range of demanding, longer texts, and recognise implicit meaning. • Can express him/herself fluently and spontaneously without much obvious searching for expressions. • Can use language flexibly and effectively for social, academic and professional purposes. • Can produce clear, well-structured, detailed text on complex subjects, showing controlled use of organisational patterns, connectors and cohesive devices.
B2	• Can understand the main ideas of complex text on both concrete and abstract topics, including technical discussions in his/her field of specialisation. • Can interact with a degree of fluency and spontaneity that makes regular interaction with native speakers quite possible without strain for either party. • Can produce clear, detailed text on a wide range of subjects and explain a viewpoint on a topical issue giving the advantages and disadvantages of various options.
B1	• Can understand the main points of clear standard input on familiar matters regularly encountered in work, school, leisure, etc. • Can deal with most situations likely to arise whilst travelling in an area where the language is spoken. • Can produce simple connected text on topics, which are familiar, or of personal interest. • Can describe experiences and events, dreams, hopes & ambitions and briefly give reasons and explanations for opinions and plans.
A2	• Can understand sentences and frequently used expressions related to areas of most immediate relevance (e.g. very basic personal and family information, shopping, local geography, employment). • Can communicate in simple and routine tasks requiring a simple and direct exchange of information on familiar and routine matters. • Can describe in simple terms aspects of his/her background, immediate environment and matters in areas of immediate need.
A1	• Can understand and use familiar everyday expressions and very basic phrases aimed at the satisfaction of needs of a concrete type. • Can introduce him/herself and others and can ask and answer questions about personal details such as where he/she lives, people he/she knows and things he/she has. • Can interact in a simple way provided the other person talks slowly and clearly and is prepared to help.

Figura 13: Niveles CEFR

B. Ejemplos de sustitución manual

Primero analizamos los textos y coloreamos en

- Rojo: Texto a eliminar
- Naranja: Sustitucion lexica a aplicar
- Violeta: Texto a escribir de otra forma

para saber qué reglas estábamos aplicando en cada parte. Es importante conservar el sentido del texto luego que esté simplificado.

Texto original: Utah monolith: Has the mysterious metal object disappeared?

A **mysterious** metal monolith discovered last week **in the desert** in the US **state of Utah has disappeared**, officials say.

Utah's Bureau of Land Management said **it** had seen **credible** reports the object had been removed "**by an unknown party**".

Social media images apparently from the site show a pile of rocks and a small piece of metal left behind.

The discovery of the 12ft (3.7m) high object sparked a national guessing game as to how it got there, and saw dozens of people pay a visit in recent days.

The strange metal object was first spotted on 18 November by a helicopter crew counting big horn sheep from the air, in a remote south-eastern area of Utah.

News of its discovery and speculation over its origins quickly went viral on social media, with many observers **presuming** it was an art installation left by a sculptor.

As yet no-one has claimed responsibility for installing the **structure**.

Ryan Bacher, **a Utah helicopter pilot who visited the site on Friday afternoon**, told local TV station KSL that when his friend returned the next day it had gone.

"Twenty-four hours later, my close friend, who is also a helicopter pilot, flew his family down to see as well and found it taken down,"he said, adding he would like to know who did it.

The **state's** Bureau of Land Management (BLM) said in a statement it had not removed "the structure which is considered private property".

"We do not investigate crimes involving private property which are handled by the local sheriff's office,"it added.

Several people posted images on social media **said to be from the site**, posing with what remained of the monolith.

Last week, **the Utah Department of Public Safety Aero Bureau** released images of the **mysterious metal object**, but did not **disclose its exact** location **fearing explorers may try to seek it out and "become stranded"**.

However, this did not stop dozens - perhaps even hundreds - of curious sight-seers from flocking to the site in recent days after internet sleuths were able to track down the monolith's GPS coordinates.

But the mystery of its origins remain.

The pilot of the helicopter who made the discovery, Bret Hutchings, speculates the monolith may have been installed by "some new wave artist." or a fan of 2001: A Space Odyssey, the 1968 film directed by Stanley Kubrick.

Imposing black monoliths created by an unseen alien species appear in the movie, based on the writings of novelist Arthur C Clarke.

Officials said it was likely a work of art, but its installation on public land was illegal, "no matter what planet you are from".

Texto simplificado: Utah monolith: Has the mysterious metal object disappeared?

Officials say a metal monolith discovered last week in the US has disappeared.

The officials said they had seen reports the object had been removed.

Images from social media show only rocks and a small piece of metal were left behind.

The 3.7m high monolith had everyone guessing as to how it got there. Dozens of people paid a visit after its discovery.

Many observers believed it was an art installation left by a sculptor.

No-one has claimed responsibility for installing or removing the monolith.

Ryan Bacher told a local TV station that when his close friend went with his family to see the monolith, it had gone.

The Bureau of Land Management officials said in a statement that they had not removed "the structure which is considered private property". They added that they don't investigate crimes involving private property.

A lot of people posted images on social media posing with what remained of the monolith.

Last week, officials released images of the monolith, but did not reveal the location, because they feared explorers may get lost. However, hundreds of people went to the site after being able to track down the monolith thanks to the internet.

But the mystery of its origins remain.

Bret Hutchings is the helicopter pilot who made the discovery. He thinks the monolith was installed by "some new wave artist" or a fan of the movie 2001: A Space Odyssey.

Black monoliths created by aliens appear in the movie.

Officials said it was likely a work of art, but its installation was illegal, "no matter what planet you are from".

Texto original: In Lucia's neighborhood

My name is Lucia.

My grandmother has been telling me about Jane Jacobs. She was a lady who talked about neighborhoods.

She talked about the people in them, the things they do and what makes a neighborhood nice.

She talked about neighborhoods like mine.

This story is about my neighborhood. About the people I see. The work they do. The houses they live in. About the things that happen here every day.

My neighborhood is pretty busy in the morning. People are going to work, going to school or going to the park! The park is great.

All kinds of people go there - big people, medium people and little people.

I really like the Tai Chi people.

I see them practicing every morning.

There also joggers and dog walkers.

All the dog walkers let their dogs run free in the off-leash area.

The dogs really like it.

Soon the shops start to open.

The workers have lots of work to do.

The neighbours do, too.

Flowers have to be bought.

Yards must be made beautiful!

Some yards have flowers.

Other yards have sculptures.

Some yards even have tree sculptures!

And some trees are trimmed just like the olive trees in Portugal.

Look! Here comes the letter carrier.

It must be twelve o'clock.

Some kids are coming home from daycare.

School kids are coming home for lunch.

Yum! Grandmother made my favorite soup!

In the afternoon, everyone has somewhere to go and someone to see. There's a lot to talk about.

Every summer there's a parade for the Senhor Da Pedra Festival.

My street is decorated just like in Portugal.

Everybody makes the decorations together.

But my favorite part will come next.

I love to listen to the band marching down the street.

I've been daydreaming about it for weeks!

At the end of the day, people come home for dinner and things quiet down.

After dinner, everybody's out again.
People sit on their porches. Kids play in their yards.
Grandmas sit in the sun. Teenagers hang out.
Some people head up to College Street.
Some people go out for a late dinner.
Others do a little shopping.
Everybody likes this shop. It has fresh fruits and vegetables at good prices.
Time to go home!
At night, College Street is still busy.
But my street is pretty quiet.
Just a few people are still out.
When I see Mr. Ferrara going back to work, I know it's time for bed.
And that's the end of my story.
The story of an average day in my neighborhood.

Texto simplificado: In Lucia's neighborhood

My name is Lucia. My grandmother has been telling me about Jane Jacobs. She was a lady who talked about neighborhoods. This story is about my neighborhood.

My neighborhood is very busy in the morning. People go to work, go to school or go to the park! All kinds of people go there. People do Tai Chi. There are also joggers and dog walkers.

Soon the shops start to open. Workers have a lot of work to do. Neighbours work in their gardens.

At twelve o'clock kids come home for lunch. In the afternoon, everyone has a place to go and someone to see.

At the end of the day, people come home for dinner and things quiet down. After dinner, everybody's out again. At night, my neighborhood is still busy. But my street is pretty quiet. It's time for bed.

And that's the end of my story. The story of a normal day in my neighborhood.

Texto original: The best mariachi in the world

Gustavo was the worst mariachi in the world. Everyone else in the family band could play an instrument. But not Gustavo. He did not play songs at weddings or at restaurants. He did not wear a charro suit or a mariachi hat.

Sometimes he reached for the bow of his brother Raymundo's violin. Raymundo quietly said "Don't touch the bow of my violin. You might break it. It is not for you."

Sometimes Gustavo tried to play his uncle Enrique's brass trumpet. Uncle Enrique gently said, "Put down the trumpet. You might drop it. It is not for you."

Gustavo did not even try to pick up his father's big guitar. It was taller than he was.

Gustavo wondered how it would feel to strum the long strings, the long strings. He imagined everyone would listen. People would look at him. The men and women would get up and dance. All the children would dance and clap.

He would be Gustavo, the great mariachi.

(He wanted to play.) But that would never happen. No one would let him play. He would always be the worst mariachi in the world.

Even his cousins would not let him try to play their big guitar, or play a trumpet or violin.

They would say "This is not for you."

"Hmm," Gustavo thought, "I want to be in the band - in the mariachi band. But what can I do?"

Gustavo got up one morning before dawn. He looked out into the desert and saw the cacti. The saguaros stood like huge trees. The nopales lay close to the ground. The sky was a black bowl of stars. Somewhere an owl hooted. A coyote padded over the sand. Everything was beautiful.

No one was there to play. But he had to stand up and sing. He just had to sing. He sang softly at first, barely moving his lips.

The next day he got up a little earlier. He sang in a whisper.

The day after that Gustavo sang a little bit louder.

The following day he sang louder still. He did not think about where he was or how early it was.

Before the first rooster crowed, before the first light of day peeked out from the east, Gustavo sang, and sang at the top of his voice.

One by one, the lights in the houses came on.

A man called out, "What is happening?"

A woman wondered, "Who is that?"

A child asked, "Who is that singer?"

Gustavo kept singing.

He sang of traveling men. He sang of faraway places and of coming home again.

He sang all the songs he knew. He sang all the songs that he knew like his own name.

A crowd of people came out to listen.

At last Gustavo finished singing. He was done with his songs. He turned to go inside. It was time to feed the chickens.

The people started to clap. They liked his singing! They were clapping for his singing.

“Gustavo!” they called out. “Bravo!” “Very good!”

They kept clapping. Women waved their handkerchiefs.

His brother gave him a big hug and said “You are a real mariachi.”

His father said, “You, my son, just may be the best mariachi in the world.”

His cousins carried Gustavo, the best mariachi, into the house. They made him a huge breakfast. Then they fed the chickens for him.

The next time the band played, Gustavo wore a charro suit. He wore a hat. He sang the songs that had brought everyone outside.

All the people clapped and cheered. He took off his hat and took a deep bow.

“This,” Gustavo thought, “is for me.”

Texto simplificado: The best mariachi in the world

Gustavo was the worst mariachi in the world. Everyone else in the family band could play an instrument. But not Gustavo.

Sometimes he tried to touch his brother’s violin, his uncle’s trumpet, but they always said “It is not for you.”

His father’s big guitar was even taller than he was.

He wanted to play. But no one would let him play.

His cousins would not let him play their big guitar, play a trumpet or violin.

“Hmm,” Gustavo thought, “I want to be in the band - in the mariachi band. But what can I do?”

Gustavo got up very early one morning. He went to the desert. He started to sing.

First, he sang softly.

The next day he got up a little earlier. He sang in a whisper.

The day after Gustavo sang a little bit louder.

The following day he sang louder. Gustavo sang, and sang at the top of his voice.

One by one, the lights in the houses came on.

A man shouted, “What is happening?”

A woman said, “Who is that?”

A child asked, “Who is that singer?”

Gustavo kept singing.

He sang all the songs he knew.

A lot of people came out to listen.
The people started to clap. They liked his singing!
“Gustavo!”. “Bravo!” “Very good!”
His brother said, “You are a real mariachi.”
His father said, “You are, maybe, the best mariachi in the world.”
The next time the band played, Gustavo wore a charro suit. He wore a hat. He sang the songs.
All the people clapped. He took off his hat and took a deep bow.
“This,” Gustavo thought, “is for me.”

C. Reglas de Transformación del artículo Syntactic simplification and Text Cohesion

A continuación se presentan todas las reglas definidas para la etapa de Transformación por el autor [39]:

Cláusulas de Conjunción

La primera regla aplica para conjunciones adversativas:

$$CC_n \quad [Clause_n1 \ X], \quad [Clause_n2 \ Y]. \quad \rightarrow \begin{array}{l} (a) \ X. \\ (b) \ Y. \end{array}$$

En donde CC_n es una de las siguientes palabras: *though, although, when* o *because*.

Como ejemplo, esta regla divide el siguiente enunciado:

[CC_m Although] [$Clause_m1$ India announced troop withdrawals along the border], [$Clause_m2$ their forces in Kashmir were left intact].

En:

- (a) India announced troop withdrawals along the border.
- (b) {But} their forces in Kashmir were left intact.

La segunda regla aplica en conjunciones correlativas de *if... then* y con *if* subordinantes donde la división se realizaría si las cláusulas son unidas por *then* o una coma:

$$[_m \text{ If}] [Clause_m1 \ X] [then|,] [Clause_m2 \ Y]. \quad \rightarrow \begin{array}{l} (a) \ X. \\ (b) \ Y. \end{array}$$

Ejemplo, divide:

[CC_n If] [$Clause_n1$ people have got in place proper effective safety measures], [CC_n then] [$Clause_n2$ naturally we are pleased about that].

En:

- (a) {Suppose} people have got in place proper effective safety measures.
- (b) {Then} naturally we are pleased about that.

La tercera regla aplica para cláusulas coordinadas y subordinadas:

$$[Clause_n1 \ X] \quad [,]? \quad [_n \ CC] \quad [Clause_n2 \ Y] \quad \rightarrow \begin{array}{l} (a) \ X. \\ (b) \ Y. \end{array}$$

donde la conjunción CC es una de las siguientes palabras: *though, although, but, and, because, since, as, before, after* y *when*, y donde la coma es opcional.

Ejemplo, divide:

[$Clause_n1$ I have been involved with badgers for 24 years] [$_n$ and] [$Clause_n2$ I have never heard of anything like this].

En:

- (a) I have been involved with badgers for 24 years.
- (b) {And} I have never heard of anything like this.

Las palabras entre llaves corresponden a palabras seleccionadas en la etapa de regeneración.

Cláusulas Relativas

$$V W_{NP}^x X [_{RC_n} RELPR^{\#x} Y] Z. \rightarrow \begin{array}{l} (a) V W X Z. \\ (b) W Y. \end{array}$$

$$V W_{NP}^x X [_{RC_n} RELPR^{\#x} Y] Z. \rightarrow \begin{array}{l} (a) V W X. \\ (b) W Y. \end{array}$$

Las reglas indican que si en el texto analizado, una cláusula relativa $RELPR Y$ corresponde a un sintagma nominal W , entonces se extrae $W Y$ a un nuevo enunciado.

Por ejemplo, se transforma:

[Garret Boone]¹, [$_{RC_n}$ who^{#1} teaches art at Earlham College], calls the new structure “just an ugly bridge” and one that blocks the view of a new park below.

En:

- (a) Garret Boone calls the new structure “just an ugly bridge” and one that blocks the view of a new park below.
- (b) Garret Boone teaches art at Earlham College.

Expresiones Apositivas

$$U V_{NP}^x W, [_{appos_n} X^{\#x} Y], Z. \rightarrow \begin{array}{l} (a) U V W Z. \\ (b) V Aux X Y. \end{array}$$

$$U V_{NP}^x W, [_{appos_n} X^{\#x} Y]. \rightarrow \begin{array}{l} (a) U V W. \\ (b) V Aux X Y. \end{array}$$

Transforma:

Pierre Vinken, 61 years old, will join the board as a non executive director Nov. 29.

En:

- (a) Pierre Vinken will join the board as a non executive director Nov. 29.
- (b) Pierre Vinken is 61 years old.

Conjunción	Cue-Word
although, though, but	but
or	or
if, if...then	suppose...then
because	so
and	and

Cuadro 17: Cue-Words introducidas para conjunciones

D. POS Tags del Penn Treebank Project

[28]

Tag	Description	Example	Tag	Description	Example	Tag	Description	Example
CC	coordinating conjunction	<i>and, but, or</i>	PDT	predeterminer	<i>all, both</i>	VBP	verb non-3sg present	<i>eat</i>
CD	cardinal number	<i>one, two</i>	POS	possessive ending	<i>'s</i>	VBZ	verb 3sg pres	<i>eats</i>
DT	determiner	<i>a, the</i>	PRP	personal pronoun	<i>I, you, he</i>	WDT	wh-determ.	<i>which, that</i>
EX	existential 'there'	<i>there</i>	PRP\$	possess. pronoun	<i>your, one's</i>	WP	wh-pronoun	<i>what, who</i>
FW	foreign word	<i>mea culpa</i>	RB	adverb	<i>quickly</i>	WP\$	wh-possess.	<i>whose</i>
IN	preposition/ subordin-conj	<i>of, in, by</i>	RBR	comparative adverb	<i>faster</i>	WRB	wh-adverb	<i>how, where</i>
JJ	adjective	<i>yellow</i>	RBS	superlatv. adverb	<i>fastest</i>	\$	dollar sign	<i>\$</i>
JJR	comparative adj	<i>bigger</i>	RP	particle	<i>up, off</i>	#	pound sign	<i>#</i>
JJS	superlative adj	<i>wildest</i>	SYM	symbol	<i>+, %, &</i>	“	left quote	<i>' or “</i>
LS	list item marker	<i>1, 2, One</i>	TO	“to”	<i>to</i>	”	right quote	<i>' or ”</i>
MD	modal	<i>can, should</i>	UH	interjection	<i>ah, oops</i>	(	left paren	<i>[, (, {, <</i>
NN	sing or mass noun	<i>llama</i>	VB	verb base form	<i>eat</i>	)	right paren	<i>],), }, ></i>
NNS	noun, plural	<i>llamas</i>	VBD	verb past tense	<i>ate</i>	,	comma	<i>,</i>
NNP	proper noun, sing.	<i>IBM</i>	VBG	verb gerund	<i>eating</i>	.	sent-end punc	<i>. ! ?</i>
NNPS	proper noun, plu.	<i>Carolinas</i>	VBN	verb past part.	<i>eaten</i>	:	sent-mid punc	<i>: ; ... --</i>

Figura 14: POS Tags utilizadas en el Penn Treebank Project

E. Tablas de resultado métricas

De los textos obtenidos en Readworks se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en el Cuadro 18.

Evaluación de ReadWorks con métricas						
Métrica	K	1	2	3	4	5
Smog Index	5.75	6.34	7.69	8.4	9.55	9.77
Flesh Kincaid Grade	2.26	2.92	4.64	5.66	6.95	7.62
Coleman Liau Index	4.74	5.7	7.39	8.23	9.25	9.64
Automated Readability Index	3.24	4.19	6.28	7.56	9.03	10.02
Dale Chall Readability Score	3.56	4.4	5.42	5.88	6.5	6.65
Linsear Write Formula	3.26	3.87	5.18	6.43	7.46	8.29
Gunning Fog	3.89	4.44	5.95	6.97	8.25	8.92
Text Standard	3.88	4.56	5.88	6.76	7.99	8.7

Cuadro 18: Evaluación de ReadWorks con métricas

De los textos obtenidos en Newsela se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en el Cuadro 19.

Evaluación de Newsela con métricas						
Métrica	2	3	4	5	6	7
Smog Index	7.21	8.23	9.54	10.74	12.08	13.21
Flesh Kincaid Grade	3.71	5.11	7.01	9.0	11.37	13.08
Coleman Liau Index	7.09	8.29	9.24	9.98	10.68	11.34
Automated Readability Index	5.93	7.63	9.85	12.26	15.2	17.27
Dale Chall Readability Score	4.99	5.56	6.19	6.63	7.16	7.56
Linsear Write Formula	3.61	4.39	5.46	6.83	8.29	9.74
Gunning Fog	5.39	6.54	8.42	10.44	12.86	14.55
Text Standard	5.61	6.49	8.21	9.74	11.27	12.53

Métrica	8	9	10	11	12
Smog Index	14.67	15.7	17.18	17.6	17.59
Flesh Kincaid Grade	16.35	17.64	22.09	22.95	23.46
Coleman Liau Index	11.63	12.28	12.11	12.23	12.16
Automated Readability Index	21.42	22.9	28.71	30.1	30.35
Dale Chall Readability Score	8.09	8.41	8.93	9.37	9.18
Linsear Write Formula	11.55	12.62	15.79	17.0	15.93
Gunning Fog	17.99	19.18	23.82	25.52	25.35
Text Standard	13.65	15.06	15.1	16.0	17.46

Cuadro 19: Evaluación de Newsela con métricas

De los textos obtenidos en ISL Collective se eligieron al azar 100 textos por nivel y se calculó el promedio de métricas de evaluación presentadas en el Cuadro 20.

Evaluación de textos de ISL Collective con métricas						
Métrica	Pre-A1	A1	A2	B1	B2	C1
Smog Index	6.03	8.81	11.04	11.63	12.28	12.51
Flesh Kincaid Grade	8.4	6.51	10.41	14.49	13.03	13.07
Coleman Liau Index	4.99	7.7	9.4	9.99	10.08	10.25
Automated Readability Index	10.1	8.4	13.07	17.62	16.52	16.65
Dale Chall Readability Score	4.61	5.85	6.81	7.49	7.57	7.54
Linsear Write Formula	4.46	6.93	10.61	11.5	10.97	13.07
Gunning Fog	10.14	8.3	11.88	15.52	14.67	14.61
Text Standard	5.55	7.58	10.68	11.9	11.9	12.75

Cuadro 20: Evaluación de textos de ISL Collective con métricas